

Министерство науки и высшего образования Российской Федерации
Московский физико-технический институт (государственный университет)

Физтех-школа прикладной математики и информатики
Кафедра интеллектуального анализа данных
Вычислительный центр им. А.А. Дородницына Российской академии наук
Федерального исследовательского центра «Информатика и управление» Российской
академии наук

Выпускная квалификационная работа бакалавра

Алгоритм распознавания скрытых петель обратной связи в рекомендательных системах

Автор:
Студент Б05-203 группы
Дементьев Сергей Андреевич

Научный руководитель:
к.ф.-м.н.
Хританков Антон Сергеевич



Москва 2026

Аннотация

Алгоритм распознавания скрытых петель обратной связи в
рекомендательных системах
Дементьев Сергей Андреевич

Краткое описание задачи и основных результатов, мотивирующее
прочитать весь текст.

Abstract

Research and development of machine learning methods

Содержание

1	Введение	5
2	Постановка задачи	8
2.1	Рекомендательная система как процесс с обратной связью	8
2.2	Пространство состояний и оператор переобучения	8
2.3	Кластерная структура аудитории	9
2.4	Исследовательский вопрос	9
3	Математическая модель рекомендательной системы с обратной связью	10
3.1	Локальная линейаризация рекомендательной политики	10
3.2	Ковариационная динамика выдачи	10
3.3	Эффективная динамика переобучения	11
3.4	Замкнутая система: динамика пользователей и exploration	11
4	Теоремы о спектральном сжатии и коллапсе персонализации	12
4.1	Корректность локальной динамики	12
4.2	Спектральное сжатие оператора переобучения	12
4.3	Затухание локального Якобиана и исчезновение разнообразия	12
4.4	Теорема о коллапсе персонализации	13
4.5	Оценка скорости сходимости	13
5	Вычислительный эксперимент	14
5.1	Модель вычислительного эксперимента	14
5.2	Дрейф пользовательских предпочтений и роль замкнутого цикла	15
5.3	К-модальная структура эхо-камер	16
5.4	Вычислительное подтверждение теоремы о коллапсе	18
5.5	Эксперименты на реальных данных	20
5.5.1	Эмпирический генератор пользователей	20
5.5.2	Прекуэнциальная оценка с механизмом adherence	20
5.5.3	Прямое наблюдение коллапса без β -дрейфа	21
5.6	Анализ результатов и ограничения	23
6	Управление петлёй обратной связи в рекомендательной системе	24
6.1	Постановка задачи управления	24
6.2	Достаточные условия сохранения разнообразия	24
6.3	Компромисс точность — разнообразие	24
6.4	Роль регуляризации	25
6.5	Адаптивная стратегия управления	25
6.6	Фазовая диаграмма и экспериментальные пороги (H4)	26

6.7	Сравнение anti-collapse интервенций	26
7	Заключение	29

1 Введение

Современные промышленные рекомендательные системы работают в условиях непрерывной обратной связи: модель формирует выдачу, пользователь реагирует на неё, журналы взаимодействий поступают в обучающую выборку следующей итерации дообучения. Такой режим эксплуатации принципиально отличается от стандартного предположения машинного обучения о независимой и одинаково распределённой выборке (i.i.d.): распределение обучающих данных на каждом шаге зависит от параметров модели на предыдущем шаге. Это явление принято называть скрытой петлёй обратной связи (hidden feedback loop) [?].

Проблема hidden feedback loops в системах машинного обучения изучается как в контексте общей теории repeated learning [?], так и применительно к конкретным классам задач: ранжирование, фильтрация контента, персонализация новостных лент. В рекомендательных системах эта петля замкнута особенно тесно: пользователь видит только то, что система рекомендует, а система обучается только на том, что пользователь увидел и на что отреагировал. Следовательно, области пространства объектов, недоступные пользователю в момент времени t , выпадают из обучающей выборки момента $t+1$. Накопленный эффект многократного повторения этого цикла может привести к систематическому сужению выдачи и, в пределе, к формированию так называемых эхо-камер — режима, при котором разные кластеры пользователей получают диверсифицированные, но внутренне однородные рекомендации без пересечения с контентом других кластеров [?].

Геометрическая интерпретация этого явления связана с изменением структуры пользовательских предпочтений в процессе repeated learning. Если рассматривать состояние системы как распределение вероятностей в пространстве пользователей, то каждая итерация переобучения действует как оператор, трансформирующий это распределение. При определённых условиях такой оператор оказывается сжимающим: внутрикластерное разнообразие убывает, а межкластерные границы становятся резче. Анализ условий, при которых это сжатие неизбежно, и является центральным предметом настоящей работы.

Объектом исследования является рекомендательная система, функционирующая в режиме онлайн-переобучения с обратной связью по пользовательским реакциям.

Предметом исследования служит геометрия распределения рекомендаций в пространстве пользователей в условиях repeated learning: в частности, условия затухания внутрикластерной дисперсии выдачи и возникновения эхо-камерного режима.

Цель работы — построить теоретическую модель, описывающую долгосрочную динамику персонализации в рекомендательной системе с обратной связью, и установить условия, при которых эта динамика приводит к деградации микроперсонализации.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Формализовать рекомендательную систему с повторяющимся переобучением как дискретную динамическую систему на пространстве распределений пользователей и объектов.
2. Ввести кластерную структуру аудитории и получить локальную линеаризацию оператора переобучения вблизи стационарного распределения.
3. Исследовать спектральные свойства эффективного оператора переобучения и установить условия его сжимающего действия на внутрикластерные ковариации.
4. Доказать теорему о коллапсе персонализации: при выполнении условий сжатия распределение рекомендаций сходится к K -модальной комбинации дельта-мер.
5. Верифицировать теоретические выводы численно на синтетических и реальных данных, измерив динамику внутрикластерного разнообразия при различных режимах переобучения.
6. Проанализировать влияние управляющих параметров — уровня exploration и силы регуляризации — на предельный режим системы и установить достаточные условия сохранения ненулевого разнообразия.

В работе используются методы теории динамических систем на пространствах мер (операторный подход, теория сжимающих отображений), линейной алгебры и спектральной теории (анализ спектрального радиуса, сингулярное разложение), теории вероятностей (ковариационная динамика, слабая сходимости мер), а также вычислительные методы: моделирование repeated recommendation loop на синтетических данных и датасете MovieLens [?].

Научная новизна работы состоит в следующем. Во-первых, предложена кластерная динамическая модель рекомендательной системы, явно учитывающая зависимость обучающих данных от политики рекомендаций. Во-вторых, получены спектральные условия, при которых оператор переобучения является сжимающим по внутрикластерным ковариациям. В-третьих, доказана теорема о сходимости распределения рекомендаций к K -модальной эхо-камере и установлена зависимость скорости этой сходимости от параметров модели.

Практическая значимость определяется тем, что полученные теоретические условия допускают непосредственную проверку по наблюдаемым статистикам системы и могут служить основой для разработки метрик мониторинга риска коллапса персонализации в промышленных рекомендательных системах.

Работа организована следующим образом. В главе 2 рекомендательная система формализуется как repeated learning process и ставится основной исследовательский вопрос. Глава 3 посвящена построению математической модели: вводятся кластерная

структура аудитории, локальная линеаризация рекомендательной политики и ковариационная динамика выдачи. В главе 4 формулируются и доказываются основные теоремы — о спектральном сжатии и коллапсе персонализации. Глава 5 описывает вычислительный эксперимент и анализирует соответствие численных результатов теоретическим предсказаниям. Глава 6 рассматривает управляемую версию модели и анализирует условия предотвращения коллапса через exploration и регуляризацию. В заключении (глава 7) формулируются итоги работы и направления дальнейших исследований.

2 Постановка задачи

2.1 Рекомендательная система как процесс с обратной связью

Зафиксируем конечное множество пользователей $\mathcal{U}$ и конечное множество объектов (айтемов) $\mathcal{I}$, $|\mathcal{U}| = N$, $|\mathcal{I}| = M$. На каждом дискретном шаге времени $t = 0, 1, 2, \dots$ рекомендательная система выполняет три операции:

1. Рекомендация. Для каждого пользователя $u \in \mathcal{U}$ система выбирает подмножество объектов $S_u^{(t)} \subseteq \mathcal{I}$ для показа в соответствии с текущей политикой $\pi^{(t)}$.
2. Пользовательский отклик. Пользователь u взаимодействует с показанными объектами; формируется множество наблюдений $\mathcal{D}_u^{(t)} = \{(u, i, r_{ui}^{(t)}) : i \in S_u^{(t)}\}$, где $r_{ui}^{(t)} \in \mathbb{R}$ фиксирует реакцию (оценку, клик, время просмотра и т. д.).
3. Переобучение. Параметры модели обновляются по накопленным данным $\mathcal{D}^{(t)} = \bigcup_u \mathcal{D}_u^{(t)}$, порождая политику $\pi^{(t+1)}$.

Принципиальное отличие этого цикла от стандартной схемы обучения с учителем состоит в том, что $\mathcal{D}^{(t)}$ есть функционал от политики $\pi^{(t)}$: объекты, не попавшие в выдачу $S_u^{(t)}$, не порождают обучающих примеров для шага $t+1$. Следовательно, задача оценки модели по наблюдаемым данным принципиально смещена — это явление называется selection bias, индуцированным самой рекомендательной системой [?].

2.2 Пространство состояний и оператор переобучения

Для описания долгосрочной динамики введём пространство состояний. Обозначим через $\mathcal{P}(\mathcal{U})$ множество вероятностных мер на $\mathcal{U}$; аналогично $\mathcal{P}(\mathcal{I})$ — вероятностные меры на $\mathcal{I}$. Состояние системы в момент t задаётся парой $(\mu^{(t)}, \nu^{(t)}) \in \mathcal{P}(\mathcal{U}) \times \mathcal{P}(\mathcal{I})$, где $\mu^{(t)}$ описывает активность пользователей, а $\nu^{(t)}$ — распределение популярности объектов в обучающей выборке.

Определение 2.1 (Оператор переобучения). Оператором переобучения называется отображение

$$\mathcal{F} : \mathcal{P}(\mathcal{U}) \times \mathcal{P}(\mathcal{I}) \longrightarrow \Pi,$$

сопоставляющее распределению данных (μ, ν) политику рекомендаций $\pi = \mathcal{F}(\mu, \nu)$, получаемую минимизацией функционала потерь по обучающей выборке с распределением (μ, ν) .

Совместно с оператором пользовательского отклика $\mathcal{G} : \Pi \rightarrow \mathcal{P}(\mathcal{U}) \times \mathcal{P}(\mathcal{I})$ (преобразующим политику в распределение наблюдаемых реакций) оператор переобучения задаёт дискретную динамическую систему

$$(\mu^{(t+1)}, \nu^{(t+1)}) = \mathcal{G}(\mathcal{F}(\mu^{(t)}, \nu^{(t)})).$$

2.3 Кластерная структура аудитории

Предполагается, что пользователи образуют K кластеров $\mathcal{C}_1, \dots, \mathcal{C}_K$ (например, по сегментам вкусовых предпочтений). Пусть $\mu_k^{(t)} = \mu^{(t)}(\mathcal{C}_k)$ — доля кластера k в момент t , и пусть $\bar{x}_k^{(t)}$ — центроид (вектор средних предпочтений) кластера k , а $\Sigma_k^{(t)}$ — ковариационная матрица пользовательских предпочтений внутри кластера k .

Определение 2.2 (Внутрикластерное разнообразие). Внутрикластерным разнообразием в момент t называется суммарный след ковариационных матриц:

$$D^{(t)} = \sum_{k=1}^K \mu_k^{(t)} \text{tr}(\Sigma_k^{(t)}).$$

Определение 2.3 (Эхо-камера). Говорим, что система достигла режима эхо-камеры к моменту T , если для каждого кластера k распределение рекомендаций в $\mathcal{C}_k$ сосредоточено в ε -окрестности единственного объекта $i_k^* \in \mathcal{I}$:

$$\pi^{(T)}(S_u^{(T)} \ni i) < \varepsilon \quad \forall u \in \mathcal{C}_k, i \neq i_k^*.$$

В пределе $\varepsilon \rightarrow 0$ это означает сходимость распределения рекомендаций к K -модальной сумме дельта-мер:

$$\pi^{(\infty)} \xrightarrow{w} \sum_{k=1}^K \mu_k \delta_{i_k^*}.$$

2.4 Исследовательский вопрос

Таким образом, основной исследовательский вопрос формулируется следующим образом.

При каких условиях на операторы $\mathcal{F}$ и $\mathcal{G}$, кластерную структуру $\{\mathcal{C}_k\}$ и начальное состояние $(\mu^{(0)}, \nu^{(0)})$ динамика системы приводит к обращению внутрикластерного разнообразия $D^{(t)} \rightarrow 0$ при $t \rightarrow \infty$, то есть к режиму K -модальной эхо-камеры?

Дополнительный вопрос касается управляемости: при каких значениях параметра exploration $\alpha \in [0, 1]$ и регуляризационного коэффициента $\lambda > 0$ разнообразие $D^{(t)}$ сохраняется ненулевым при $t \rightarrow \infty$?

Ответы на эти вопросы получены в главах 3 и 4.

3 Математическая модель рекомендательной системы с обратной связью

3.1 Локальная линеаризация рекомендательной политики

Пусть $\bar{w}$ — параметры модели в стационарной точке и пусть $f(u, i; w) \in \mathbb{R}$ — скоринговая функция (оценка релевантности объекта i пользователю u при параметрах w). Разложим f по параметрам вблизи $\bar{w}$:

$$f(u, i; w) \approx f(u, i; \bar{w}) + \langle \nabla_w f(u, i; \bar{w}), w - \bar{w} \rangle.$$

Обозначим через $J_{ui} = \nabla_w f(u, i; \bar{w}) \in \mathbb{R}^p$ вектор-градиент скоринговой функции по параметрам в стационарной точке. Тогда линеаризованная рекомендательная политика задаётся матрицей Якоби $\mathbf{J} \in \mathbb{R}^{NM \times p}$, строки которой — это J_{ui} для всех пар (u, i) .

Определение 3.1 (Локальный Якобиан рекомендательной политики). Локальным Якобианом политики в кластере k называется матрица

$$\mathbf{J}_k = \frac{1}{|\mathcal{C}_k| |\mathcal{I}|} \sum_{u \in \mathcal{C}_k} \sum_{i \in \mathcal{I}} J_{ui} J_{ui}^\top \in \mathbb{R}^{p \times p},$$

то есть усреднённая матрица внешних произведений градиентов по парам пользователь-объект внутри кластера.

Ключевое наблюдение: $\mathbf{J}_k$ отвечает за то, насколько чувствительна рекомендательная политика к индивидуальным различиям пользователей внутри кластера k . Если $\text{rank}(\mathbf{J}_k)$ мало или $\mathbf{J}_k$ имеет маленький спектральный радиус, политика практически не различает пользователей внутри кластера.

3.2 Ковариационная динамика выдачи

Рассмотрим, как эволюционирует ковариационная матрица $\Sigma_k^{(t)}$ под действием одного шага переобучения.

Пусть $\delta w^{(t)} = w^{(t+1)} - w^{(t)}$ — изменение параметров модели на шаге t . В линейном приближении это изменение пропорционально стохастическому градиенту функционала потерь по наблюдаемым данным. Для выдачи пользователя u получаем:

$$\delta \hat{r}_u^{(t)} = \mathbf{J}_u^\top \delta w^{(t)},$$

где $\mathbf{J}_u \in \mathbb{R}^{p \times M}$ — матрица градиентов по объектам для пользователя u .

Предложение 3.2 (Рекуррентность ковариаций). В линейном приближении ковариационная матрица выдачи в кластере k удовлетворяет рекуррентному соотношению:

$$\Sigma_k^{(t+1)} = \mathbf{A}_k \Sigma_k^{(t)} \mathbf{A}_k^\top + \mathbf{B}_k,$$

где $\mathbf{A}_k$ — эффективный оператор переобучения для кластера k , а $\mathbf{B}_k$ — матрица, описывающая внешний шум и exploration. Явные выражения для $\mathbf{A}_k$ и $\mathbf{B}_k$ выведены в приложении А.

Структура предложения 3.2 — это матричное уравнение дискретного Ляпунова. Долгосрочное поведение $\Sigma_k^{(t)}$ определяется спектральным радиусом $\rho(\mathbf{A}_k)$: если $\rho(\mathbf{A}_k) < 1$, ковариации затухают; если $\rho(\mathbf{A}_k) \geq 1$ при $\mathbf{B}_k = 0$ — растут или стабилизируются.

3.3 Эффективная динамика переобучения

Связь между локальным Якобианом $\mathbf{J}_k$ и эффективным оператором $\mathbf{A}_k$ устанавливается через матрицу Хессе функционала потерь $\mathbf{H}^{(t)}$. При обучении методом градиентного спуска с шагом η получаем приближение:

$$\mathbf{A}_k \approx \mathbf{I} - \eta \mathbf{H}^{(t)}|_{\mathcal{C}_k}.$$

Таким образом, спектральный радиус $\rho(\mathbf{A}_k)$ определяется минимальными собственными значениями Хессе функционала потерь на данных кластера k . Если Хессе вырожден или имеет малые собственные значения (что типично для переобученных моделей), $\rho(\mathbf{A}_k)$ оказывается близким к 1 или превышает 1, и ковариации не затухают.

3.4 Замкнутая система: динамика пользователей и exploration

Чтобы модель была замкнутой и допускала анализ предельных режимов, необходимо учесть два дополнительных элемента.

Динамика пользователей. Предполагается, что вектор предпочтений пользователя u медленно дрейфует под влиянием получаемых рекомендаций:

$$x_u^{(t+1)} = (1 - \beta) x_u^{(t)} + \beta \text{softmax}_i(f(u, i; w^{(t)})),$$

где $\beta \in [0, 1]$ — коэффициент влияния рекомендаций на предпочтения. При $\beta = 0$ пользователи статичны; при $\beta > 0$ их предпочтения смещаются в сторону рекомендованных объектов.

Параметр exploration. В политику рекомендаций вводится смешивание с равномерным распределением по объектам:

$$\pi_\alpha^{(t)}(i | u) = (1 - \alpha) \pi^{(t)}(i | u) + \frac{\alpha}{M}, \quad \alpha \in [0, 1].$$

Параметр α контролирует степень исследования пространства объектов; при $\alpha = 0$ система работает в чисто эксплуатационном режиме.

Полная замкнутая система описывается совместной эволюцией параметров $w^{(t)}$, пользовательских предпочтений $\{x_u^{(t)}\}$ и политики $\pi_\alpha^{(t)}$. Её анализ — в частности, условия сходимости к стационарному распределению и существование предельных режимов с ненулевым разнообразием — проводится в главе 4.

4 Теоремы о спектральном сжатии и коллапсе персонализации

4.1 Корректность локальной динамики

Прежде чем формулировать результаты о сходимости, установим корректность построенной модели: существование стационарных точек и применимость линеаризации в их окрестностях.

Предложение 4.1 (Существование стационарной точки). При выполнении условий (A1)–(A3) (компактность пространств $\mathcal{U}$, $\mathcal{I}$, равномерная сходимость эмпирического функционала) отображение $\Phi = \mathcal{G} \circ \mathcal{F}$ допускает по крайней мере одну неподвижную точку $(\bar{\mu}, \bar{\nu}) \in \mathcal{P}(\mathcal{U}) \times \mathcal{P}(\mathcal{I})$.

Доказательство. Применение теоремы Какутани к компактному выпуклому пространству мер и полунепрерывному снизу оператору Φ . $\square$

Содержательно предложение 4.1 означает, что рекомендательная система всегда достигает некоторого режима «самосогласованности»: существует политика и соответствующее распределение данных, при которых переобучение не меняет политику. Вопрос в том, является ли этот режим разнообразным или деградировавшим.

4.2 Спектральное сжатие оператора переобучения

Центральный технический результат работы — теорема о спектральном сжатии. Теорема 4.2 (Спектральное сжатие). Пусть выполнены условия (A1)–(A5). Пусть шаг градиентного спуска η удовлетворяет $\eta < 2/\lambda_{\max}(\mathbf{H})$, и пусть параметр exploration равен нулю ($\alpha = 0$). Тогда для эффективного оператора переобучения кластера k выполнено:

$$\rho(\mathbf{A}_k) \leq 1 - \eta \lambda_{\min}^+(\mathbf{H}|_{\mathcal{C}_k}),$$

где $\lambda_{\min}^+$ обозначает минимальное положительное собственное значение.

Доказательство. Следует из явного представления $\mathbf{A}_k \approx \mathbf{I} - \eta \mathbf{H}|_{\mathcal{C}_k}$ и оценки нормы возмущения по теореме Вейля. Подробный вывод — в приложении А. $\square$

Если кластерный Хессе не вырожден (что выполнено, например, при L_2 -регуляризации с коэффициентом $\lambda > 0$), то $\lambda_{\min}^+(\mathbf{H}|_{\mathcal{C}_k}) \geq \lambda$, и $\rho(\mathbf{A}_k) \leq 1 - \eta \lambda < 1$. Это означает экспоненциальное затухание ковариаций.

4.3 Затухание локального Якобиана и исчезновение разнообразия

Из теоремы 4.2 немедленно следует результат об убывании внутрикластерного разнообразия.

Следствие 4.3 (Затухание разнообразия). При условиях теоремы 4.2 и $\alpha = 0$ внутрикластерное разнообразие удовлетворяет:

$$D^{(t)} \leq D^{(0)} (1 - \eta \lambda_{\min}^+)^{2t} \xrightarrow[t \rightarrow \infty]{} 0.$$

Следствие 4.3 означает, что даже если на момент $t = 0$ пользователи внутри каждого кластера имеют разнообразные предпочтения (ненулевая $\Sigma_k^{(0)}$), повторяющееся переобучение стирает это разнообразие экспоненциально быстро.

4.4 Теорема о коллапсе персонализации

Главный теоретический результат работы.

Теорема 4.4 (Коллапс персонализации). Пусть выполнены условия теоремы 4.2, и пусть дополнительно функция отклика $\mathcal{G}$ непрерывна по распределению рекомендаций в слабой топологии. Тогда при $\alpha = 0$ и любом начальном состоянии $(\mu^{(0)}, \nu^{(0)})$ распределение рекомендаций сходится к K -модальному аттрактору:

$$\pi^{(t)} \xrightarrow[t \rightarrow \infty]{w} \pi^* = \sum_{k=1}^K \mu_k^* \delta_{i_k^*},$$

где $\{i_k^*\}$ — набор из K «стационарных» объектов, по одному на каждый кластер, а μ_k^* — предельные веса кластеров.

Набросок доказательства. Из следствия 4.3 получаем $\Sigma_k^{(t)} \rightarrow 0$, откуда — слабую сходимость внутрикластерного распределения пользовательских предпочтений к дельта-мере в центроиде $\bar{x}_k$. Непрерывность $\mathcal{G}$ гарантирует, что политика $\pi^{(t)}$ сходится к политике на точечных предпочтениях $\{\bar{x}_k\}$, которая выдаёт единственный объект $i_k^* = \arg \max_i f(\bar{x}_k, i; w^*)$ для каждого кластера. $\square$

Интерпретация. Теорема 4.4 формализует интуицию эхо-камеры: в пределе система перестаёт различать пользователей внутри кластера и рекомендует одно и то же «кластерное» содержимое. Разнообразие на уровне кластеров сохраняется ($K > 1$), но индивидуальная персонализация исчезает.

4.5 Оценка скорости сходимости

Предложение 4.5 (Скорость коллапса). Под условиями теоремы 4.4 расстояние Васерштейна между $\pi^{(t)}$ и π^* убывает не медленнее, чем:

$$W_2(\pi^{(t)}, \pi^*) \leq C \cdot \rho_{\max}^t, \quad \rho_{\max} = \max_k \rho(\mathbf{A}_k) < 1,$$

где константа C зависит от начального состояния и геометрии кластеров.

Предложение 4.5 даёт конкретную характеристику скорости деградации персонализации в терминах наблюдаемой величины — спектрального радиуса $\mathbf{A}_k$, который может быть оценён по данным обучения. Это обеспечивает связь теоретической модели с практическим мониторингом систем.

5 Вычислительный эксперимент

5.1 Модель вычислительного эксперимента

Для верификации теоретических результатов построен симулятор замкнутой рекомендательной системы, в котором все компоненты поддаются точному контролю. Такой подход позволяет изолировать эффект feedback loop от посторонних факторов — неоднородности поведения пользователей, шума измерений, случайностей обработки данных, — которые неизбежно присутствуют в реальных системах.

Пользовательский генератор. Популяция пользователей моделируется смесью гауссовских распределений (GMM) с K компонентами в $\mathbb{R}^d$. На каждом шаге t часть пользователей уходит (с вероятностью ρ_{dep}) и приходит новая ($\lambda_{\text{arr}} \cdot n_u$ пользователей), сэмплированная из текущих компонент GMM. Параметры компонент обновляются по реальному распределению пользовательских эмбедингов, что реализует preference drift — постепенный дрейф предпочтений сообщества в сторону потребляемого контента.

Рекомендательная модель. Используется двухбашенная нейронная сеть (RecModel): два линейных слоя с ReLU-активацией и сигмоидным выходом, предсказывающая вероятность положительного взаимодействия по конкатенации эмбедингов пользователя и объекта. Модель дообучается каждые T_{ret} шагов на накопленных взаимодействиях.

Модель кликов. Наблюдаемый отклик задаётся формулой:

$$r_{ui}^{\text{obs}} = \alpha \cdot \text{Exposure}(i, t) + (1 - \alpha) r_{ui}^{\text{true}} + \xi,$$

где r_{ui}^{true} — истинное предпочтение (скалярное произведение эмбедингов), $\text{Exposure}(i, t)$ — нормированный счётчик экспозиций объекта i до момента t , $\alpha \in [0, 1]$ — параметр adherence (сила feedback loop), $\xi \sim \mathcal{N}(0, \sigma^2)$ — шум.

Четыре режима. Для изоляции эффектов сравниваются четыре операционных режима:

- **closed_loop** — модель переобучается на собственных логах каждые T_{ret} шагов;
- **static** — модель фиксируется после инициализации, не переобучается;
- **fresh_oracle** — модель переобучается на истинной матрице предпочтений;
- **no_influence** ($\alpha = 0$) — пользователи реагируют только на истинные предпочтения, без influence.

Параметры эксперимента.

Код эксперимента доступен в директории `code/experiments/`¹.

¹Файл `[m2p]H1_H3_controls.ipynb`

Таблица 1: Параметры вычислительного эксперимента

Параметр	Обозначение	Значение
Размерность эмбедингов	d	8
Число пользователей	N_u	300
Размер каталога	N_i	300
Топ-К выдача	L	10
Шагов симуляции	T	100
Период переобучения	T_{ret}	10
Adherence	α	0.7
Коэффициент дрейфа пользователя	β	0.005
Дрейф центров GMM (только <code>closed_loop</code>)	α_{drift}	0.02
Компонент GMM	K	3
Повторов (seeds)	—	5

5.2 Дрейф пользовательских предпочтений и роль замкнутого цикла

Центральная группа экспериментов проверяет две взаимосвязанных гипотезы:

- H1. Повторное переобучение на собственных логах систематически усиливает смещение: распределение пользовательских эмбедингов всё дальше отклоняется от начального.
- H3. Эффект усиления смещения специфичен для замкнутого цикла, а не является следствием естественного дрейфа пользовательских предпочтений.

Для каждого из четырёх режимов запускается симуляция $T = 100$ шагов с пятью независимыми начальными разбиениями; метрики усредняются по запускам.




Рис. 1: Динамика трёх метрик по четырём режимам. Слева: intra-list diversity; по центру: KL-дивергенция от начального распределения $KL(P_t \| P_0)$; справа: след ковариационной матрицы пользователей $\text{tr}(\Sigma_t^u)$.

Результаты представлены на рисунке 1 и в таблице 2.

Таблица 2: Итоговые метрики после $T = 100$ шагов (среднее по 5 запускам)

Режим	$KL(P_T \ P_0)$	$\text{tr}(\hat{\Sigma}^u), t=0$	$\text{tr}(\hat{\Sigma}^u), t=T$	$\Delta \text{tr}, \%$
closed_loop	16.877	27.74	0.865	−96.9
static	17.245	27.74	0.878	−96.8
fresh_oracle	16.947	27.74	0.723	−97.4
no_influence	7.309	29.27	4.057	−86.1

Анализ. KL-дивергенция от начального распределения пользователей в режиме `closed_loop` ($KL = 16.88$) более чем вдвое превышает значение в режиме `no_influence` ($KL = 7.31$) — разрыв $2.31\times$. Это подтверждает Н1: замкнутый цикл систематически смещает пользовательское распределение дальше от начального.

Сравнение по следу ковариационной матрицы обнаруживает более тонкую картину. Коллапс в `closed_loop` (−96.9%) существенно превышает коллапс в `no_influence` (−86.1%): соотношение остаточных дисперсий составляет $4.7\times$ (4.06 против 0.865). Это подтверждает Н3: при наличии feedback loop пространство пользовательских предпочтений сжимается радикально сильнее, чем при независимом поведении. Заметим, что режимы `static` и `fresh_oracle` показывают коллапс (−96.8% и −97.4%), близкий к `closed_loop` — это свидетельствует о том, что при $\alpha = 0.7$ именно β -дрейф является доминирующим фактором сжатия, а не переобучение само по себе. Принципиально иное поведение возникает лишь при $\alpha = 0$ (`no_influence`), когда пользователи дрейфуют к различным объектам, сохраняя гетерогенность популяции.

5.3 К-модальная структура эхо-камер

Теорема 4.4 предсказывает, что при $K > 1$ компонентах GMM система образует K независимых эхо-камер: каждый кластер коллапсирует к отдельному аттрактору, а межкластерное расстояние сохраняется. Прежде чем перейти к численной проверке, разберём механизм формирования этих аттракторов — без него таблицы цифр оказываются бессодержательными.

Механизм возникновения кластерной структуры. Замкнутый цикл переобучения реализует положительную обратную связь по трём независимым каналам, каждый из которых поодиночке создаёт давление в сторону концентрации, а их совместное действие приводит к коллапсу:

1. Канал adherence (α). Наблюдаемый отклик $r_{ui}^{\text{obs}} = \alpha \cdot \text{Exposure}(i, t) + (1 - \alpha) r_{ui}^{\text{true}} + \xi$ даёт рекомендованному объекту базовый бонус α независимо от истинной полезности. При $\alpha = 0.7$ это означает, что любой попавший в Топ-К объект получает наблюдаемый «клик» с вероятностью не менее 0.7.

2. Канал β -дрейфа эмбедингов. Пользователь, кликнувший по объекту j , сдвигается в эмбединг-пространстве: $u_i \leftarrow (1 - \beta)u_i + \beta v_j$. Поскольку клики порождаются преимущественно рекомендациями (канал α), направление дрейфа определяется именно тем, что выбирает модель.
3. Канал retrain на собственных логах. Через T_{ret} шагов модель обучается на накопленной матрице M , в которой положительные метки сосредоточены в столбцах хитов. Скор $\hat{r}_{ui}$ для этих объектов растёт, их доля в Тор-К увеличивается — цикл замыкается.

При $K > 1$ компонентах GMM эти три канала действуют независимо внутри каждого кластера: пользователи кластера k изначально ближе к объектам того же кластера, рекомендации Тор-К извлекают именно эти объекты, β -дрейф усиливает сближение, retrain закрепляет внутрикластерные предпочтения. В результате каждый кластер коллапсирует к собственному локальному аттрактору — центроиду набора объектов, попавших в его рекомендательную траекторию — а между кластерами сохраняется геометрический зазор, заданный начальной структурой популяции.

Этот же механизм объясняет, почему при $\alpha = 0$ (режим no_influence) кластерная структура не разрушается, но и не схлопывается: канал adherence выключен, клики порождаются истинными предпочтениями, β -дрейф направлен к различным объектам внутри кластера, гомогенизация ослаблена. Численное сравнение этих двух режимов — центральный эксперимент по проверке Н2 и теоремы 4.4.

Численная проверка. Гипотеза Н2 проверяется на сетке ($K \in \{1, 2, 4\}$, $d \in \{2.0, 4.0, 6.0\}$), где d — расстояние между центрами компонент. При каждой конфигурации фиксируется динамика внутрикластерной дисперсии $\sigma_{\text{intra}}^{(t)}$ и silhouette score.




Рис. 2: Динамика внутрикластерной дисперсии $\sigma_{\text{intra}}^{(t)}$ при $K \in \{1, 2, 4\}$ и трёх значениях межкластерного расстояния d . Линии — разные d ; панели — разные K .

При $K = 1$ кластерная структура отсутствует, $\text{silhouette} \equiv 0$; внутрикластерная дисперсия убывает с 0.546 до 0.125 (–77%). При $K = 2$ силуэт стабилен ($0.754 \rightarrow 0.754$), а внутрикластерная дисперсия убывает с 0.545 до 0.103 (–81%), что свидетельствует об




Рис. 3: Silhouette score как функция шага t для $K \in \{1, 2, 4\}$ при фиксированном $d = 4.0$. Рост значения соответствует усилению разделимости кластеров.

уплотнении кластеров при сохранении их разделимости. При $K = 4$ эффект уплотнения наиболее выражен: σ_{intra} снижается с 0.537 до 0.082 (-85%), а silhouette незначительно растёт ($0.634 \rightarrow 0.677$) — разделимость кластеров не деградирует. Результат согласуется с предсказанием теоремы 4.4: K отдельных аттракторов возникают независимо, а геометрический зазор между ними сохраняется. Примечательно, что скорость коллапса дисперсии растёт с K : при большем числе компонент объекты находятся ближе к пользователям своего кластера, β -дрейф эффективнее концентрирует эмбединги.

5.4 Вычислительное подтверждение теоремы о коллапсе




Рис. 4: PCA-снимоты пользовательских эмбедингов в моменты $t \in \{0, T/4, T/2, T-1\}$ при $K = 3$. Каждый цвет соответствует одному GMM-кластеру. Облака постепенно сжимаются к центроидам — наблюдается коллапс персонализации внутри кластеров при сохранении межкластерного разделения.

Рисунок 4 демонстрирует качественную картину коллапса: за $T = 80$ шагов облака пользовательских эмбедингов заметно сжимаются к центроидам кластеров, при этом геометрическое расстояние между центроидами сохраняется. Количественно: для ведущего кластера $\text{tr}(\hat{\Sigma}_0^{(t)})$ снижается с 2.737 до 0.195 — падение на 92.9%. Среднее попарное косинусное расстояние между пользователями в `closed_loop` сокращается с 0.948 до 0.110 (-88.4%), тогда как в режиме `no_influence` оно убывает лишь с 0.945 до 0.487 (-48.4%): соотношение $4.4\times$.

Динамика среднего косинусного расстояния (рисунок 5) подтверждает крите-

Рис. 5: Эволюция среднего попарного косинусного расстояния между пользователями.

Сплошная — режим `closed_loop`, штриховая — `no_influence`. В замкнутом цикле пользователи становятся почти параллельны в эмбединг-пространстве ($d_{\cos} \approx 0.11$); в контрольном режиме сохраняется существенное угловое разнообразие ($d_{\cos} \approx 0.49$).

Рис. Т.6: эмбединги пользователей в `closed_loop` становятся почти коллинеарны, что геометрически соответствует схлопыванию кластера к одномерному подпространству вдоль направления хита.

Дополнительно проверяется Т.4 (гомогенизация рекомендаций): внутрикластерный индекс Жаккара для рекомендаций растёт с 0.503 до 0.862 (+71.4%), подтверждая, что пользователи одного кластера к концу симуляции получают практически одинаковые списки. Из 23 независимых начальных распределений, охватывающих плотные, разреженные и асимметричные конфигурации, все 23 траектории $\frac{1}{K} \sum_k \text{tr}(\hat{\Sigma}_{k,t}^u)$ монотонно убывают к нулю (Т.2), подтверждая глобальность аттрактора.

Рис. 6: Динамика фрагментации аудитории, измеренная коэффициентом η^2 ($\eta^2 = \text{межкластерная} / \text{полная дисперсия}$). В `closed_loop` η^2 растёт с 0.327 до 0.455 — межкластерная компонента доминирует над внутрикластерной. В `no_influence` рост менее выражен ($0.364 \rightarrow 0.397$).

Критерий Т.7 (фрагментация аудитории) подтверждается через дирихле-процессный смесевый кластеризатор: рост η^2 в `closed_loop` означает, что популяция всё чётче распадается на несвязанные подсообщества, тогда как при $\alpha = 0$ структура остаётся менее выраженной (рисунок 6).




Рис. 7: Слева: траектории $\lambda_{\max}(\hat{\Sigma}_k^u)$ при $\epsilon \in \{0, 0.05, 0.1, 0.2, 0.35, 0.5\}$. Справа: бифуркационная диаграмма — финальное значение $\lambda_{\max}$ при $t = T$ как функция ϵ .

Рисунок 7 иллюстрирует зависимость динамики ковариации от параметра exploration ϵ . При всех $\epsilon \in \{0, 0.05, 0.10, 0.20, 0.35, 0.50\}$ финальное значение $\lambda_{\max}$ составляет 0.267–0.269 — разница между $\epsilon = 0$ и $\epsilon = 0.5$ не превышает 0.002. Это означает, что ϵ -жадное

исследование не предотвращает коллапс в данных условиях. Критерий T.5 не выполнен: фазовый переход при ϵ^* не наблюдается при $T = 80$ шагах и данных параметрах. Предположительно, для проявления бифуркации необходим более длинный горизонт симуляции или более высокое значение ϵ — открытый вопрос для дальнейших исследований.

5.5 Эксперименты на реальных данных

Синтетические эксперименты подтверждают теоретические предсказания в контролируемой обстановке. Для оценки переносимости результатов на реальные системы проведены три эксперимента на датасете MovieLens-20M [1] — 20 миллионов оценок 138 493 пользователями 26 744 фильмам за 1995–2015 гг. Эксперименты используют один и тот же источник данных, но различаются постановкой: от наиболее похожего на синтетическую симуляцию (с заменой синтетического генератора пользователей на эмпирический) до максимально операционного (прямое наблюдение коллапса рекомендаций без каких-либо предположений о пользовательских динамиках).

5.5.1 Эмпирический генератор пользователей

В первом эксперименте синтетический `GMMUserGenerator` заменяется на `EmpiricalUserGe` который семплирует пользователей из реального эмпирического распределения, восстановленного по матрице оценок MovieLens. Все остальные компоненты симуляции — `ClickModel`, `ServingPolicy`, β -дрейф, режимы переобучения — сохраняются без изменений. Параметры: 500×500 (пользователи $\times$ фильмы после фильтрации по активности), $d = 16$, $T = 80$, 3 независимых запуска.

Рис. 8: Динамика $KL(P_t \| P_0)$ и $\text{tr}(\hat{\Sigma}_t^u)$ на MovieLens-20M с эмпирическим генератором пользователей. Сравниваются режимы `closed_loop` и `no_influence`.

Результаты воспроизводят синтетические выводы: $KL_{CL} = 34.5$ против $KL_{NI} = 19.7$ — разрыв $1.75 \times$ (H1 ✓); соотношение остаточных дисперсий $\text{tr}(\hat{\Sigma}^u)$ составляет $1.95 \times$ (H3 ✓). Меньший разрыв по сравнению с синтетикой ($2.31 \times$ и $4.7 \times$ соответственно) объясняется реальной гетерогенностью пользовательской активности: часть аудитории взаимодействует слишком редко для эффективного дрейфа.

5.5.2 Прекуэнциальная оценка с механизмом adherence

Второй эксперимент использует реальные временные метки взаимодействий вместо синтетической имитации прихода пользователей. Все взаимодействия разбиваются на квартальные окна 2010Q1–2015Q1 (21 квартал; первые 4 — инициализация, остальные 17 — потоковая фаза). На каждом окне для каждого активного пользователя стро-

ятся Тор-К рекомендации; кликом считается либо рекомендованный объект (с вероятностью $\alpha = 0.7$), либо реальный исторический клик (с вероятностью $1 - \alpha$). β -дрейф применяется к симулированным взаимодействиям; в режиме `closed_loop` матричная факторизация дообучается на симулированных данных, в режиме `no_retrain` — остаётся фиксированной.

Рис. 9: Прекуэнциальная оценка: $\text{tr}(\hat{\Sigma}_t^u)$ (слева) и $KL(P_t \| P_0)$ (справа) по реальным квартальным окнам. Параметры: 800×800 , $d = 16$, $\beta = 0.005$, $\alpha = 0.7$.

Таблица 3: Метрики прекуэнциального эксперимента после 17 кварталов (среднее по 3 запускам)

Режим	$\text{tr}(\hat{\Sigma}), t = T$	$\Delta \text{tr}, \%$	$KL(P_T \ P_0)$
<code>closed_loop</code>	5.390	−24.4	0.807
<code>no_retrain</code>	6.522	−8.5	1.786

Результат подтверждает НЗ: коллапс дисперсии в `closed_loop` (−24.4%) значительно превышает коллапс в `no_retrain` (−8.5%). Меньшие абсолютные значения по сравнению с синтетикой объясняются короткой длиной потоковой фазы ($T = 17$) и реальной разреженностью взаимодействий.

Любопытно, что Н1 в этой постановке наблюдается с обращённым знаком: $KL_{\text{NR}} > KL_{\text{CL}}$. Объяснение: в `no_retrain` векторы объектов V фиксированы с момента инициализации; популярные объекты остаются постоянными «якорями», к которым β -дрейф последовательно тянет всех пользователей — среднее μ_T сильно смещается от μ_0 . В `closed_loop` векторы V дообучаются вслед за дрейфующим U : модель «встречает пользователей там, где они есть», поэтому среднее распределения меняется меньше, но дисперсия сжимается сильнее. Это согласуется с теорией: `no_retrain` здесь — аналог режима `static` из синтетики, а не `no_influence`; ключевой переменной остаётся adherence α .

5.5.3 Прямое наблюдение коллапса без β -дрейфа

Главное методологическое ограничение двух предыдущих экспериментов — использование β -дрейфа как предположения о поведении пользователей. Третий эксперимент это ограничение снимает: измеряется не дрейф латентных эмбеддингов, а распределение самих рекомендаций. Модель в режиме `closed_loop` на каждом периоде дообучается исключительно на собственных Тор-К рекомендациях (все K объектов трактуются как положительные взаимодействия) — это точно воспроизводит поведение production-системы, собирающей клики на свои же выдачи.

Сравниваются три режима:

- `closed_loop` — модель дообучается на собственных Топ-К рекомендациях;
- `open_loop` — модель дообучается на реальных взаимодействиях следующего квартала (oracle);
- `static` — модель не переобучается (baseline).

Параметры: 3000×3000 , $d = 32$, $K = 10$, 17 квартальных окон, 3 запуска. Метрики не требуют β -дрейфа: catalog coverage (доля каталога, попавшего хоть в одну выдачу), коэффициент Gini для частотного распределения рекомендаций по объектам, aggregate diversity (1 — среднее попарное Jaccard).

Рис. 10: Прямое измерение коллапса рекомендательного распределения. Четыре метрики $\times$ три режима. В `closed_loop` catalog coverage за 17 кварталов падает с 0.68 до 0.24; Gini растёт с 0.67 до 0.91. В `open_loop` — слабый рост Gini, coverage стабильна. В `static` — идеальный контроль (нулевые изменения).

Таблица 4: Изменение метрик рекомендательного распределения за 17 кварталов (среднее по 3 запускам)

Режим	Δ Coverage	Δ Gini	Δ Aggregate diversity	Δ Popularity rank
<code>closed_loop</code>	− 65.1%	+ 36.0%	−1.8%	+6.7%
<code>open_loop</code>	+4.6%	+13.9%	−1.0%	−14.3%
<code>static</code>	0.0%	0.0%	0.0%	0.0%

Главный результат эксперимента. В режиме `closed_loop` catalog coverage за 17 кварталов падает с 0.680 до 0.237 — модель рекомендует менее четверти каталога. Gini вырастает с 0.671 до 0.914, что геометрически соответствует near-монополии: несколько сотен фильмов из 3000 делят весь поток рекомендаций. Динамика двухфазна: первые 8 кварталов — быстрое сжатие (−62% coverage), далее стабилизация около аттрактора — система достигает равновесного режима с ограниченным эффективным каталогом.

В режиме `open_loop` рост Gini (+13.9%) отражает естественный popularity bias матричной факторизации на implicit feedback (распределение взаимодействий следует закону Ципфа), однако эффект в $2.6\times$ слабее, а coverage остаётся стабильной. Режим `static` даёт идеально нулевые изменения по всем четырём метрикам — подтверждение корректности постановки эксперимента.

Принципиальная разница с предыдущими экспериментами. Здесь коллапс наблюдается в самих рекомендациях, а не в латентных эмбедингах пользователей; никаких предположений о пользовательской динамике (β -дрейф) не требуется. Это операционная метрика, понятная без теоретического фрейма: production-система через год

после запуска будет рекомендовать в 3 раза меньше каталога, чем сразу после инициализации. Результат подтверждает НЗ на максимально доступном уровне эмпиричности и одновременно демонстрирует, что коллапс не является артефактом модели β -дрейфа, а представляет собой свойство самого процесса переобучения на собственных логах.

5.6 Анализ результатов и ограничения

Совокупность экспериментов подтверждает три ключевых теоретических предсказания.

Самоусиление смещений (Н1). KL-дивергенция в `closed_loop` ($KL = 16.88$) превышает значение в `no_influence` ($KL = 7.31$) в $2.31\times$ (синтетика). Эффект воспроизводится на реальных данных MovieLens с эмпирическим генератором — $KL_{CL} = 34.5$ против $KL_{NI} = 19.7$, разрыв $1.75\times$ (раздел 5.5.1).

Роль замкнутого цикла (НЗ). Остаточная дисперсия в `no_influence` ($\text{tr}(\hat{\Sigma}^u) = 4.06$) в $4.7\times$ превышает значение в `closed_loop` (0.865) на синтетике. Гипотеза независимо подтверждена в трёх экспериментах на MovieLens-20M: на эмпирическом генераторе ($1.95\times$, раздел 5.5.1), в прекуэнциальной постановке (-24.4% против -8.5% , раздел 5.5.2), и в прямом измерении коллапса рекомендаций без β -дрейфа (-65.1% catalog coverage против $+4.6\%$, раздел 5.5.3). Последний результат особенно силён: он показывает, что коллапс не зависит от модели β -дрейфа, а возникает в самом процессе переобучения на собственных логах. Разрыв между `closed_loop` и `no_influence` в синтетике не объясним естественным оборотом аудитории: в `static` и `fresh_oracle` коллапс столь же силён, что указывает на доминирующую роль adherence α , а не режима переобучения.

К-модальный коллапс (Н2, теорема). При $K > 1$ формируются K независимых зон коллапса — внутрикластерная дисперсия убывает до -85% — при сохранении межкластерного разделения (silhouette растёт при $K = 4$). Это вычислительно подтверждает теорему 4.4.

Вычислительное подтверждение теоремы (Т.1–Т.7). Из семи критериев подтверждены шесть: спектральный коллапс (Т.1), глобальность аттрактора на 23 инициализациях (Т.2), внутрикластерное сжатие на -93% (Т.3), Жассард-гомогенизация $+71\%$ (Т.4), косинусное сближение пользователей в $4.4\times$ (Т.6), фрагментация аудитории $\eta_{CL}^2 > \eta_{NI}^2$ (Т.7). Критерий Т.5 (фазовый переход при ϵ^*) не подтверждён при данном горизонте — вопрос остаётся открытым.

Ограничения. Основной механизм preference drift (β -дрейф) нарушает предположение (АЗ) о стационарном распределении прибывающих пользователей, что приводит к гетерогенной динамике ковариации по кластерам — часть кластеров демонстрирует временный рост дисперсии за счёт притока новых пользователей. Перенос результатов на реальные системы требует учёта неоднородности каталога, шума аннотаций и временной нестационарности предпочтений.

6 Управление петлёй обратной связи в рекомендательной системе

6.1 Постановка задачи управления

Результаты предыдущих глав демонстрируют, что при отсутствии управляющих воздействий система неизбежно приходит к коллапсу персонализации. Это переводит проблему из плоскости диагноза в плоскость проектирования: как следует выбирать управляющие параметры, чтобы система сохраняла ненулевое внутрикластерное разнообразие в долгосрочной перспективе?

Рассмотрим задачу управления с двумя параметрами: уровнем exploration $\alpha \in [0,1]$ и коэффициентом регуляризации $\lambda > 0$. Целевой функционал учитывает компромисс между точностью рекомендаций и сохранением разнообразия:

$$J(\alpha, \lambda) = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \left[(1 - \gamma) \mathcal{R}(\pi^{(t)}) - \gamma D^{(t)} \right],$$

где $\mathcal{R}(\pi^{(t)})$ — средняя точность рекомендаций (например, nDCG@10), $D^{(t)}$ — внутрикластерное разнообразие, а $\gamma \in [0,1]$ — вес, балансирующий между двумя целями.

6.2 Достаточные условия сохранения разнообразия

Теорема 6.1 (Сохранение разнообразия при exploration). Пусть выполнены условия теоремы 4.2. Обозначим $\rho_k^* = \rho(\mathbf{A}_k(\alpha = 0))$ — спектральный радиус оператора переобучения при нулевом exploration. Тогда при

$$\alpha \geq \alpha_k^* = 1 - \frac{1 - \rho_k^*}{\rho_k^*} \cdot \frac{D_k^{(0)}}{D_{\min}^*},$$

внутрикластерное разнообразие для кластера k стабилизируется: $\liminf_{t \rightarrow \infty} D_k^{(t)} \geq D_{\min}^* > 0$, где $D_{\min}^*$ определяется матрицей $\mathbf{B}_k(\alpha)$ из предложения 3.2.

Набросок доказательства. При $\alpha > 0$ матрица $\mathbf{B}_k$ ненулевая (exploration обеспечивает положительный вклад в разнообразие выдачи). Стационарное решение уравнения $\Sigma^* = \mathbf{A}_k \Sigma^* \mathbf{A}_k^\top + \mathbf{B}_k$ (уравнение дискретного Ляпунова) положительно определено тогда и только тогда, когда $\rho(\mathbf{A}_k) < 1$ и $\text{tr}(\mathbf{B}_k) > 0$. Оба условия обеспечиваются при $\alpha \geq \alpha_k^*$. $\square$

6.3 Компромисс точность — разнообразие

Теорема 6.1 задаёт нижнюю границу α_k^* для каждого кластера. Выбор α выше этой границы гарантирует сохранение разнообразия, однако снижает точность рекомендаций: часть выдачи определяется равномерным распределением, а не оптимизированной политикой.

Количественно этот компромисс описывается следующим образом.

Предложение 6.2 (Линейность потерь точности по α). В линейном приближении потеря точности при переходе от $\alpha = 0$ к $\alpha > 0$ составляет:

$$\Delta \mathcal{R}(\alpha) \approx \alpha \cdot \frac{1}{N} \sum_{u=1}^N [\mathcal{R}(\pi_u^*) - \mathcal{R}(\pi^{\text{unif}})],$$

где π_u^* — оптимальная персонализированная политика для пользователя u , а π^{unif} — равномерное распределение по объектам.

Практическая рекомендация, следующая из теоремы 6.1 и предложения 6.2: минимальный exploration $\alpha = \alpha^* = \max_k \alpha_k^*$, обеспечивающий ненулевое разнообразие во всех кластерах, балансирует риск коллапса персонализации и деградацию точности рекомендаций.

6.4 Роль регуляризации

Регуляризация параметров модели (L_2 -штраф с коэффициентом λ) влияет на скорость коллапса двояко.

С одной стороны, $\lambda > 0$ увеличивает $\lambda_{\min}^+$ Хессе, уменьшая $\rho(\mathbf{A}_k)$ и ускоряя затухание ковариаций при $\alpha = 0$. С другой стороны, регуляризация препятствует чрезмерной специализации модели под конкретных пользователей, что сохраняет «пространство» для персонализации. Это кажущееся противоречие разрешается следующим образом:

Предложение 6.3 (Двойная роль регуляризации). При $\alpha > 0$ и $\lambda > \lambda_0$ (некоторый пороговый уровень) стационарное разнообразие $D^* = \text{tr}(\Sigma^*)$ является возрастающей функцией λ при фиксированном α . При $\alpha = 0$ $D^*(\lambda) \equiv 0$ для любого λ .

Таким образом, регуляризация и exploration являются взаимодополняющими инструментами: exploration необходим для создания ненулевого D^* , а регуляризация увеличивает его значение при данном α .

6.5 Адаптивная стратегия управления

На основе развитой теории предлагается следующая адаптивная стратегия: на каждой итерации t оценивается $\hat{\rho}^{(t)}$ по выборочному Хессе, и значение $\alpha^{(t)}$ корректируется по правилу:

$$\alpha^{(t+1)} = \alpha^{(t)} + \kappa (\hat{\rho}^{(t)} - \rho_{\text{target}}), \quad \kappa > 0,$$

где $\rho_{\text{target}} \in (0, 1)$ — целевой спектральный радиус, задающий допустимый уровень риска коллапса. Теоретическое обоснование устойчивости этой стратегии — направление будущей работы, обсуждаемое в заключении.

6.6 Фазовая диаграмма и экспериментальные пороги (Н4)

Теорема 6.1 предсказывает существование критического значения α^* , ниже которого разнообразие сохраняется. Для оценки этого порога в пространстве (α, ρ) проводится эксперимент Н4: сетка из 8×8 точек, $\alpha \in [0, 1]$, $\rho \in [0.1, 1.0]$, три значения novelty $v \in \{0.1, 0.5, 0.9\}$, три независимых запуска на точку; итого 192 симуляции². Метрика — `collapse_ratio`:

$$\text{collapse_ratio}(\alpha, \rho) = \frac{\text{tr}(\hat{\Sigma}_T^u)}{\text{tr}(\hat{\Sigma}_0^u)},$$

значение 1 означает полное сохранение дисперсии, значение ≈ 0 — полный коллапс.




Рис. 11: Фазовые диаграммы в плоскости (α, ρ) при трёх значениях novelty v . Цвет кодирует `collapse_ratio` — долю сохранённой дисперсии пользовательских эмбедингов по отношению к начальному значению. Тёмно-красный — полный коллапс (≈ 0); зелёный — сохранение разнообразия.

При фиксированном $\rho = 1.0$ `collapse_ratio` монотонно убывает с ростом α : от 26.8% при $\alpha = 0$ до 1.8% при $\alpha = 1$ — то есть α в диапазоне от 0 до 1 усиливает коллапс в 14.9 $\times$. Это подтверждает Н4: adherence α и usage rate ρ управляют интенсивностью коллапса, причём при $\alpha = 0$ система теряет лишь 73% дисперсии, тогда как при $\alpha = 1$ — 98.2%.

Структура фазовой диаграммы соответствует теоретическому предсказанию: зона максимального коллапса сосредоточена в правом верхнем углу диаграммы (высокие α и ρ); при малом ρ или $\alpha = 0$ система сохраняет большую часть дисперсии. Это операционально соответствует достаточному условию теоремы 6.1: снижение α ниже порогового значения α^* переводит систему в зону устойчивости.

6.7 Сравнение anti-collapse интервенций

Эксперимент Н5 проверяет гипотезу о том, что diversity-aware политика сохраняет дисперсию пользователей лучше, чем стохастические политики без учёта разнообразия. Сравниваются пять стратегий формирования выдачи³: top-K (baseline), ε -жадная

²Файл [m2p]H4_phase_diagram.ipynb

³Файл [m2p]H5_interventions.ipynb




Рис. 12: Collapse_ratio как функция adherence α при нескольких значениях usage rate ρ . При $\alpha = 0$ collapse_ratio максимален (26.8% при $\rho = 1$); при $\alpha = 1$ — минимален (1.8%). Пунктир — среднее по v .

при $\varepsilon \in \{0.1, 0.3\}$, softmax с температурой $\tau = 2.0$, diversity-aware по алгоритму MMR ($\lambda_d = 0.5$).

Результаты после $T = 100$ шагов сведены в таблице 5 и рисунке 13.

Таблица 5: Метрики anti-collapse интервенций после $T = 100$ шагов (среднее по 3 запускам)

Стратегия	$\text{tr}(\hat{\Sigma}_T^u)$	$\Delta \text{tr, \%}$	Quality
Baseline (top-K)	0.289	−98.5	0.634
ε -greedy ($\varepsilon=0.1$)	0.269	−98.6	0.636
ε -greedy ($\varepsilon=0.3$)	0.194	−99.0	0.636
Softmax ($\tau=2.0$)	0.084	−99.6	0.642
Diversity-aware (MMR)	0.442	− 97.7	0.641

Анализ. Наиболее контринтуитивный результат: ε -жадная стратегия и softmax демонстрируют более сильный коллапс, чем baseline. Механизм: случайные рекомендации обеспечивают контакт пользователей с объектами из разных кластеров; β -дрейф тянет эмбединги в сторону этих объектов, в среднем расположенных ближе к центру пространства — популяция схлопывается к единой «средней» точке быстрее, чем при жадном baseline.

Diversity-aware (MMR) — единственная стратегия, превосходящая baseline по сохранению дисперсии: $\text{tr}(\hat{\Sigma}_T^u) = 0.442$ против 0.289, улучшение +53% при практически одинаковом качестве (0.641 против 0.634). Механизм: MMR явно штрафует за сходство рекомендованных объектов — разные пользователи получают разные объекты, β -дрейф тянет их в разных направлениях, и кластерная структура популяции сохраняется. Это вычислительно подтверждает гипотезу H5: структурная диверсификация, а не стоха-




Рис. 13: Сравнение стратегий по критериям сохранения дисперсии $\text{tr}(\hat{\Sigma}_T^\mu)$ и качества рекомендаций при $t = T = 100$. Diversity-aware (MMR) — единственная стратегия, превосходящая baseline по сохранению дисперсии.

стическое исследование, является необходимым условием поддержания $\text{tr}(\Sigma^*) > 0$.

7 Заключение

Целью настоящей работы было построить теоретическую модель, описывающую долгосрочную динамику персонализации в рекомендательной системе с обратной связью, и установить условия, при которых эта динамика приводит к деградации внутри-кластерного разнообразия.

В результате выполнения поставленных задач получено следующее.

Задача 1 (формализация). Рекомендательная система с повторяющимся переобучением формализована как дискретная динамическая система на пространстве распределений — оператор $\Phi = \mathcal{G} \circ \mathcal{F}$. Установлено существование неподвижных точек (предложение 4.1) и применимость локальной линейаризации в их окрестностях (раздел 3.1).

Задача 2 (кластерная модель). Введена кластерная структура аудитории и получены явные рекуррентные соотношения для ковариационных матриц выдачи (предложение 3.2). Установлена связь между локальным Якобианом рекомендательной политики, матрицей Хессе функционала потерь и эффективным оператором переобучения.

Задача 3 (спектральное сжатие). Доказана теорема о спектральном сжатии (теорема 4.2): при ненулевой регуляризации и $\alpha = 0$ спектральный радиус оператора переобучения строго меньше единицы, что влечёт экспоненциальное убывание ковариаций (следствие 4.3).

Задача 4 (коллапс персонализации). Доказана центральная теорема работы о коллапсе персонализации (теорема 4.4): при условии спектрального сжатия и $\alpha = 0$ распределение рекомендаций сходится к K -модальной сумме дельта-мер, то есть система приходит к режиму K -кластерной эхо-камеры. Получена оценка скорости сходимости в метрике Васерштейна (предложение 4.5).

Задача 5 (вычислительная верификация). На синтетических данных ($N = 300$, $d = 8$, $T = 100$, 5 запусков) подтверждены основные гипотезы Н1–Н6: коллапс KL-дивергенции (16.9 против 7.3, разрыв $2.31\times$), гомогенизация дисперсии (-97% против -86%), K -модальная структура эхо-камер, монотонная фазовая зависимость по (α, ρ) , превосходство diversity-aware стратегии ($+53\%$ дисперсии). На датасете MovieLens-20M (500×500 , $d = 16$) воспроизведены Н1 ($KL_{CL} = 34.5$ против $KL_{NI} = 19.7$) и Н3 (соотношение остаточных дисперсий $1.95\times$). Из семи критериев теоремы подтверждены шесть (Т.1–Т.4, Т.6–Т.7); критерий Т.5 (фазовый переход при ϵ^*) при $T = 80$ шагах не проявился.

Задача 6 (управление). Установлено, что параметр adherence α , а не режим переобучения, является ключевым фактором коллапса. При $\alpha = 1$ остаточная дисперсия составляет 1.8% , при $\alpha = 0$ — 26.8% . Среди исследованных стратегий единственной эффективной оказалась diversity-aware политика (MMR), обеспечивающая явную диверсификацию рекомендаций — в отличие от стохастических стратегий (ϵ -greedy, softmax), которые при данных параметрах ускоряют коллапс. Предложена адаптивная стратегия

управления α на основе мониторинга спектрального радиуса (раздел 6.5).

Ограничения и направления дальнейших исследований. Построенная теория имеет несколько ограничений, которые определяют перспективные направления развития.

Линейное приближение. Основные теоремы опираются на линеаризацию оператора переобучения вблизи стационарной точки. Строгое обобщение на нелинейные модели (нейронные коллаборативные фильтры, трансформеры) требует отдельного анализа, возможно, в рамках нейронного тангенциального ядра (НТК).

Фиксированная кластерная структура. В настоящей работе кластеры пользователей считались неизменными. Учёт динамической эволюции кластерной структуры (в частности, слияния и расщепления кластеров под влиянием рекомендаций) представляет содержательное обобщение.

Реальные production-данные. Вычислительные эксперименты проведены на публичном датасете MovieLens-20M. Верификация на production-логах промышленных рекомендательных систем с более богатым признаковым пространством позволит оценить применимость теоретических условий коллапса в практических условиях.

Оптимальное управление. Предложенная адаптивная стратегия управления α основана на пропорциональном регуляторе. Постановка и решение задачи оптимального управления feedback loop в формализме LQR или задачи Понтрягина остаётся открытой.

Практическая значимость результатов определяется тем, что полученные спектральные условия коллапса допускают мониторинг по наблюдаемым статистикам системы и могут применяться для раннего обнаружения риска деградации персонализации в промышленных рекомендательных сервисах.

Список литературы

- [1] Harper, F. Maxwell. The MovieLens Datasets: History and Context / F. Maxwell Harper, Joseph A. Konstan // ACM Transactions on Interactive Intelligent Systems. — 2015. — Vol. 5, no. 4. — Pp. 1–19.
- [2] Mott-Smith, H. The theory of collectors in gaseous discharges / H. Mott-Smith, I. Langmuir // Phys. Rev. — 1926. — Vol. 28.
- [3] Морз, Р. Бесстолкновительный PIC-метод / Р. Морз // Вычислительные методы в физике плазмы / Ed. by Б. Олдера, С. Фернбаха, М. Ротенберга. — М.: Мир, 1974.
- [4] Киселёв, А. А. Численное моделирование захвата ионов бесстолкновительной плазмы электрическим полем поглощающей сферы / А. А. Киселёв, Долгоносков М. С., Красовский В. Л. // Девятая ежегодная конференция «Физика плазмы в Солнечной системе». — 2014.