

Министерство науки и высшего образования Российской Федерации
Московский физико-технический институт (государственный университет)

Физтех-школа прикладной математики и информатики
Кафедра интеллектуального анализа данных
Вычислительный центр им. А.А. Дородницына Российской академии наук
Федерального исследовательского центра «Информатика и управление» Российской
академии наук

Выпускная квалификационная работа бакалавра

Алгоритм распознавания скрытых петель обратной связи в рекомендательных системах

Автор:

Студент Б05-203 группы
Дементьев Сергей Андреевич

Научный руководитель:

к.ф.-м.н.
Хританков Антон Сергеевич



Москва 2026

Аннотация

Алгоритм распознавания скрытых петель обратной связи в рекомендательных системах Дементьев Сергей Андреевич

Рекомендательные системы периодически переобучаются на логах собственных взаимодействий, образуя замкнутый контур обратной связи, в котором наблюдаемые отклики перестают быть нейтральным измерением предпочтений. В работе построена математическая модель такого контура и установлено, что деградация персонализации складывается из двух различных каналов. Доказана теорема о стягивании разнообразия: внутрикластерный разброс предпочтений убывает геометрически под действием дрейфа вкусов по концентрированной выдаче, причём это убывание универсально и наступает даже без переобучения. Доказана теорема о переформировании выдачи: переобучение сужает ковариацию показанного контента сильнее, чем замороженная модель, оставляя отделимый след, измеримый в дисперсионной части расхождения распределений предпочтений. Получены условия активации этого следа и проверяемый порог концентрации. Теоретические выводы подтверждены серией вычислительных экспериментов на синтетических данных и наборе MovieLens-20M. Предложен практический критерий риска коллапса персонализации и показано, что явная диверсификация выдачи сохраняет разнообразие без потери качества. Результаты применимы для мониторинга и подавления нежелательных петель обратной связи в промышленных рекомендательных системах.

Abstract

Recommender systems are periodically retrained on the logs of their own interactions, forming a closed feedback loop in which observed responses are no longer a neutral measurement of user preferences. This work develops a mathematical model of the loop and shows that the degradation of personalization splits into two distinct channels. A contraction theorem is proved: the within-cluster spread of preferences decays geometrically due to preference drift towards a concentrated feed, and this decay is universal, occurring even without retraining. A reshaping theorem is proved: retraining narrows the covariance of the served content more than a frozen model does, leaving a separable trace measurable in the dispersion part of the divergence between preference distributions. Activation conditions and a verifiable concentration threshold are obtained. The theory is confirmed by a series of computational experiments on synthetic data and the MovieLens-20M dataset. A practical risk criterion is proposed, and explicit feed diversification is shown to preserve diversity without loss of quality.

Содержание

1	Введение	5
2	Постановка задачи	8
2.1	Объект и предмет исследования	8
2.2	Математическая модель	10
2.3	Используемые обозначения	12
2.4	Формулировка задачи оптимального управления	13
2.5	Решаемые задачи	14
3	Динамика замкнутой системы управления	16
3.1	Один шаг скалярной динамики	16
3.2	Завышение наблюдаемых метрик	16
3.3	Дрейф вкусов как сжимающее отображение	18
3.4	Кластеры, делимость и эхо-камера	19
3.5	Гауссова модель выдачи и резкость	20
3.6	Условие включения петли	21
4	Два канала деградации: дрейф и переобучение	22
4.1	Теорема о стягивании разнообразия	22
4.2	Теорема о переформировании выдачи	24
4.3	Метрика следа петли и условия активации	26
5	Вычислительный эксперимент	28
5.1	Постановка эксперимента	28
5.2	Универсальность стягивания разнообразия	29
5.3	K -модальная структура эхо-камер	30
5.4	Геометрия стягивания	31
5.5	Фазовая диаграмма стягивания	32
5.6	Наблюдаемое и истинное качество	33
5.7	След петлевого канала в ковариации	34
5.8	Прямая проверка оператора переобучения	36
5.9	Рост расхождения и надёжность офлайн-метрик	37
5.10	Эксперименты на реальных данных	38
5.11	Сводка: теория и эксперимент	40
6	Управление контуром обратной связи	41
6.1	Точки вмешательства	41
6.2	Сравнение стратегий выдачи	42

1 Введение

Промышленные рекомендательные системы работают в режиме непрерывной обратной связи: модель формирует выдачу, пользователь реагирует на неё, а данные о взаимодействиях поступают в обучающую выборку следующего цикла дообучения. Уже в классических обзорах рекомендательные системы описываются как алгоритмы, работающие с наблюдаемыми предпочтениями пользователей [1], однако в замкнутом контуре сами наблюдения становятся результатом предыдущей политики показа [2, 3]. Тем самым нарушается базовое предположение машинного обучения о независимой одинаково распределённой выборке: распределение обучающих данных на каждом шаге определяется самой моделью предыдущего шага. Возникающий эффект называют скрытой петлёй обратной связи (hidden feedback loop) [4, 5].

Опасность петли в том, что её трудно заметить. Наблюдаемые метрики качества (CTR, AUC, NDCG) вычисляются по тем же смещённым откликам, которые петля и порождает, поэтому они могут расти или держаться высокими ровно тогда, когда истинная полезность для пользователя падает [6]. Накопленный эффект многократного повторения цикла приводит к систематическому сужению выдачи, снижению разнообразия и, в пределе, к формированию эхо-камер — режима, в котором система перестаёт различать пользователей внутри сегмента и рекомендует им практически одинаковое содержимое [7, 8]. В работах об усилении смещений и динамике разнообразия похожий эффект трактуется как следствие многократного обучения на неявных откликах и повторного показа одних и тех же областей каталога [9, 10, 11]. Поскольку эффект развивается медленно и маскируется ростом наблюдаемых метрик, он не диагностируется стандартным A/B-тестированием на собственных данных, что делает теоретический анализ петли практически значимым.

Изучение петель обратной связи ведётся в нескольких направлениях. Первый блок работ анализирует собственно рекомендательные системы: деконволюцию предпочтений из искажённых логов [2], алгоритмическое смешение и рост однородности выдачи [6], вырожденные петли обратной связи и усиление смещений при дообучении [8, 9], а также каузальную коррекцию логов в алгоритме CAFL [3]. Второй блок связан с перформативным предсказанием: в нём модель рассматривается как часть среды, изменяющая распределение будущих данных [12], включая обзор перформативного риска [13] и модели с явным состоянием популяции [14]. Третий блок формулирует рекомендательные системы как замкнутые системы управления, где выдача выступает управляющим воздействием, а пользовательская популяция — динамическим объектом [15, 16, 17, 18]. Наконец, близкие идеи встречаются в работах о взаимодействии пользователя с рекомендациями и в RL-/MDP-постановках рекомендательных систем, где явно моделируется последовательное взаимодействие пользователя и алгоритма [19, 20, 21]. Отдельную линию образуют математические модели многократного дообучения, описывающие пре-

дельное поведение распределения пользователей [4, 22]. Настоящая работа примыкает к этим направлениям, но ставит более тонкий вопрос: разделить причины деградации и выяснить, оставляет ли само переобучение след, отделимый от естественного дрейфа предпочтений.

Объектом исследования является рекомендательная система, функционирующая в режиме периодического переобучения на собственных логах. Предметом исследования служит долгосрочная геометрия распределения пользовательских предпочтений и выдачи в таком контуре, в частности условия убывания внутрикластерного разнообразия и возникновения эхо-камерного режима.

Цель работы — построить математическую модель рекомендательного контура и установить, при каких условиях он деградирует, отделив вклад переобучения от прочих причин. Для достижения цели решаются следующие задачи.

1. Формализовать рекомендательную систему с переобучением на собственных логах как замкнутую динамическую систему и описать загрязнение логов.
2. Установить условия убывания внутрикластерного разнообразия и оценить скорость убывания в терминах параметров модели.
3. Выяснить, универсально ли это убывание по режиму работы контура, и определить, в какой геометрической характеристике распределения измерим отделимый след переобучения.
4. Проверить теоретические выводы численно на синтетических и реальных данных и предложить способы подавления нежелательного эффекта.

Методы исследования. Используются методы теории динамических систем и сжимающих отображений, линейной алгебры и матричного анализа (порядок Лёвнера, монотонность собственных значений), теории вероятностей (ковариационная динамика, мартингалы, оценки), а также вычислительное моделирование контура на синтетических данных и наборе MovieLens-20M. Выбор дискретной динамической модели согласован с перформативным предсказанием в среде с состоянием [14], а симуляционный слой близок по назначению к платформам и подходам с синтетической обратной связью для анализа последовательного взаимодействия пользователя и рекомендателя [23, 21].

Научная новизна работы состоит в разделении деградации на два различных канала. Показано, что убывание совокупного разнообразия порождается дрейфом предпочтений по концентрированной выдаче и универсально по режиму — оно наступает и без переобучения; для него получена строгая геометрическая оценка скорости (Теорема 4.3). Отдельно установлено, что переобучение оставляет собственный, отделимый след: оно сужает ковариацию выдачи сильнее, чем замороженная модель (Теорема 4.9), и этот след измерим не в объёме разброса, а в дисперсионной части расхождения

$\text{KL}(P_T \| P_0)$. Получены условия активации петлевого канала и проверяемый порог концентрации.

Практическая значимость определяется тем, что полученные условия допускают проверку по наблюдаемым статистикам системы и складываются в критерий риска коллапса персонализации, а предложенная диверсификация выдачи подтверждена как мера подавления эффекта без потери качества. В этом смысле работа дополняет каузальные подходы к разрыву петли обратной связи [3] и задачи управления рекомендательными системами, где управление выдачей балансирует вовлечённость, поляризацию, разнообразие и ограничения на качество относительно базовой системы [18, 24].

Апробация. Результаты работы продолжают исследовательскую линию по скрытым петлям обратной связи, ведущуюся на кафедре, и прошли апробацию в виде доклада на научной конференции МФТИ. Вклад автора состоит в построении и доказательстве теоретических результатов, постановке и проведении вычислительных экспериментов, обработке и анализе их результатов.

Работа организована следующим образом. В главе 2 описывается объект исследования, строится математическая модель и формулируется задача оптимального управления. Глава 3 исследует динамику замкнутой системы управления. В главе 4 формулируются и доказываются основные теоремы о двух каналах деградации. Глава 5 описывает вычислительный эксперимент и сопоставляет численные результаты с теорией. Глава 6 рассматривает управление контуром. В заключении (глава 7) подводятся итоги и намечаются направления дальнейшей работы.

2 Постановка задачи

2.1 Объект и предмет исследования

Рекомендательные системы предназначены для отбора объектов из большого каталога в соответствии с предполагаемыми интересами пользователя. Исторически эта задача возникла как один из способов преодоления информационной перегрузки: вместо просмотра всего каталога пользователь получает небольшой персонализированный список объектов, с которыми он с наибольшей вероятностью взаимодействует [1]. Под объектом далее понимается единица рекомендуемого содержания, например фильм, товар или публикация.

Статическая постановка. Пусть задано множество пользователей $\mathcal{U}$, $|\mathcal{U}| = N$, и множество объектов каталога $\mathcal{I}$, $|\mathcal{I}| = M$. Пользователю $i \in \mathcal{U}$ и объекту $j \in \mathcal{I}$ сопоставлены векторные представления $u_i \in \mathbb{R}^d$ и $v_j \in \mathbb{R}^d$. Исторические взаимодействия образуют обучающую выборку

$$\mathcal{B} = \{(i, j, y_{ij}) : (i, j) \in \Omega\},$$

где $\Omega \subseteq \mathcal{U} \times \mathcal{I}$ — множество наблюдавшихся пар, а y_{ij} — зарегистрированный отклик. Предполагается, что существует неизвестная функция полезности $g(u, v)$, определяющая интерес пользователя к объекту. Рекомендательная модель аппроксимирует её параметрической функцией $f(u, v; w)$, где w — настраиваемые параметры.

При явной обратной связи отклик представляет собой числовую оценку, например рейтинг от одного до пяти. В этом случае обучение формулируется как задача регрессии, и параметры модели могут определяться минимизацией среднеквадратичной ошибки

$$w^* = \arg \min_w \frac{1}{|\mathcal{B}|} \sum_{(i, j, y) \in \mathcal{B}} (y - f(u_i, v_j; w))^2. \quad (1)$$

Однако в промышленных системах чаще доступна неявная обратная связь: просмотр, клик, добавление в корзину или покупка. Для бинарного отклика $y \in \{0, 1\}$ модель оценивает вероятность положительного взаимодействия $f(u_i, v_j; w) \approx \mathbb{P}(y_{ij} = 1 \mid u_i, v_j)$. Тогда параметры настраиваются минимизацией бинарной кросс-энтропии

$$w^* = \arg \min_w \left\{ -\frac{1}{|\mathcal{B}|} \sum_{(i, j, y) \in \mathcal{B}} \left[y \log f(u_i, v_j; w) + (1 - y) \log (1 - f(u_i, v_j; w)) \right] + \lambda R(w) \right\}, \quad (2)$$

где $R(w)$ — регуляризатор, а $\lambda \geq 0$ — его коэффициент. Именно постановка предсказания бинарного отклика используется далее в математической модели и вычислительных экспериментах.

Обученная функция f используется не как самостоятельный конечный ответ, а для ранжирования каталога. Пусть $\mathcal{E}_i$ — множество объектов, уже просмотренных пользователем i , и $\mathcal{I}_i = \mathcal{I} \setminus \mathcal{E}_i$ — доступные кандидаты. Список из L рекомендаций

формируется по правилу

$$S_i = \text{TopL}_{j \in \mathcal{J}_i} f(u_i, v_j; w), \quad |S_i| = L. \quad (3)$$

Итак, построение рекомендательной системы включает обучение функции оценки и выбор с её помощью небольшой части каталога.

Используемые модели. В работе рассматриваются две параметризации функции f . Первая представляет собой билинейную модель матричной факторизации

$$f_{\text{MF}}(u, v; M, b) = \sigma(u^\top M v + b), \quad M \in \mathbb{R}^{d \times d}, \quad (4)$$

где M — обучаемая матрица взаимодействия, b — смещение, а $\sigma(z) = (1 + e^{-z})^{-1}$ — логистическая функция. Такая модель явно задаёт геометрию взаимодействия пользовательских и объектных представлений.

Вторая параметризация является многослойным персептроном (MLP), который получает конкатенацию представлений пользователя и объекта. Для используемой в основных экспериментах архитектуры с одним скрытым слоем

$$\begin{aligned} h(u, v) &= \text{ReLU}(W_1[u; v] + b_1), \\ f_{\text{MLP}}(u, v; w) &= \sigma(w_2^\top h(u, v) + b_2), \end{aligned} \quad (5)$$

где $w = (W_1, b_1, w_2, b_2)$ объединяет обучаемые параметры. Нелинейная модель позволяет описывать более сложные зависимости между признаками пользователя и объекта, чем билинейная форма (4) [25].

Переход к исследуемому контуру. Классическая постановка неявно рассматривает обучающую выборку $\mathcal{B}$ как заданную независимо от обучаемой функции f . В работающей системе это предположение нарушается: отклик наблюдается только для объектов, вошедших в список S_i . Следовательно, правило ранжирования (3) определяет, какие пары попадут в следующую обучающую выборку, а результат обучения влияет на последующую выдачу. Возникает повторяющийся процесс

$$\text{оценивание объектов} \longrightarrow \text{выдача} \longrightarrow \text{отклик} \longrightarrow \text{переобучение}.$$

Принципиальная особенность этого процесса состоит в том, что метки известны только для показанных объектов. Следовательно, состав будущей обучающей выборки зависит от текущей модели, а обновлённая модель изменяет последующие показы. Статическая задача ранжирования тем самым становится замкнутой стохастической динамической системой.

Объектом исследования служит рекомендательная система, которая периодически переобучается на данных собственных взаимодействий с пользователями. Предметом исследования является долгосрочная эволюция распределения пользовательских предпочтений и выдачи в таком замкнутом контуре, а также возможность отделить

вклад переобучения от прочих причин деградации. Такая постановка продолжает линию работ, где рекомендации рассматриваются не как статическое ранжирование, а как механизм, меняющий будущие данные и предпочтения пользователей [12, 26, 14].

В аналитической модели фиксируется когорта $\mathcal{U} = \{1, \dots, N\}$: индекс i на всём рассматриваемом горизонте обозначает одного и того же пользователя. Это является модельным допущением, позволяющим проследить индивидуальную траекторию предпочтений. Фиксированность когорты не означает фиксированности её состояния: векторы предпочтений u_i^t обновляются после взаимодействий. В работающей системе состав аудитории также меняется вследствие ухода и прихода пользователей; в вычислительных экспериментах этот эффект учитывается отдельным механизмом замены аудитории, но не входит в теоретическую динамику фиксированной когорты.

2.2 Математическая модель

Перейдём от статической постановки подраздела 2.1 к динамической модели. Множества $\mathcal{U}$ и $\mathcal{J}$, размерность латентного пространства d и представления объектов $v_j \in \mathbb{R}^d$ считаются фиксированными. В отличие от статической постановки, пользователю $i \in \mathcal{U}$ на шаге t сопоставляется меняющийся вектор предпочтений $u_i^t \in \mathbb{R}^d$. Начальными условиями служат $\{u_i^0\}_{i=1}^N$ и $\{v_j\}_{j=1}^M$.

Роль неизвестной функции полезности g из статической постановки играет истинный закон отклика, задаваемый фиксированным отображением $\theta : \mathbb{R}^d \times \mathbb{R}^d \rightarrow [0, 1]$. Для конкретной пары пользователь–объект его значение на шаге t обозначается скаляром

$$\theta_t^{ij} := \theta(u_i^t, v_j) = \sigma\left(\frac{\langle u_i^t, v_j \rangle}{\tau}\right), \quad \sigma(z) = \frac{1}{1 + e^{-z}}, \quad (6)$$

где $\tau > 0$ — температура. Таким образом, отображение θ не изменяется во времени, однако последовательность значений $\{\theta_t^{ij}\}_{t \geq 0}$, вообще говоря, не постоянна: при обновлении u_i^t меняется скалярное произведение с фиксированным объектом v_j . Далее под истинным откликом понимается именно текущее значение θ_t^{ij} , а не неизменная характеристика пары индексов (i, j) .

Рекомендательная модель выдаёт для каждой пары скалярную оценку

$$f_t^{ij} := f(u_i^t, v_j; w^t) \in [0, 1], \quad (7)$$

где w^t — параметры модели на шаге t . Оценка f_t^{ij} используется для ранжирования объектов и не совпадает с наблюдаемым откликом.

Обозначим через $\mathcal{E}_i^t$ множество объектов, ранее показанных пользователю i , и через $\mathcal{J}_i^t = \mathcal{J} \setminus \mathcal{E}_i^t$ — множество доступных кандидатов. Практическое правило выдачи состоит в том, что просмотренный объект не рекомендуется тому же пользователю повторно. Поэтому список рекомендаций имеет вид

$$S_i^t = \text{TopL}_{j \in \mathcal{J}_i^t} f_t^{ij}, \quad |S_i^t| = L. \quad (8)$$

Фильтрация просмотренного изменяет множество допустимых объектов, но не меняет уравнения отклика и обновления предпочтений.

Для каждого показанного объекта $j \in S_i^t$ наблюдаемая вероятность отклика задаётся скалярной смесью

$$\eta_t^{ij} = (1 - \alpha)\theta_t^{ij} + \alpha f_t^{ij}, \quad \alpha = ps \in [0, 1], \quad (9)$$

где s характеризует степень следования рекомендации, p — долю сигнала модели, возвращаемую в обучение, а α — совокупную силу обратной связи. Реализованный бинарный отклик удовлетворяет

$$Y_t^{ij} \sim \text{Bern}(\eta_t^{ij}), \quad j \in S_i^t. \quad (10)$$

Пусть $a_t^i \in \{0, 1\}$ показывает, произошло ли на шаге t взаимодействие, изменяющее состояние пользователя, а $j(i, t) \in S_i^t$ — выбранный им объект. Тогда динамика предпочтений задаётся уравнением

$$u_i^{t+1} = \begin{cases} (1 - \beta)u_i^t + \beta v_{j(i, t)}, & a_t^i = 1, \\ u_i^t, & a_t^i = 0, \end{cases} \quad \mathbb{P}(a_t^i = 1) = \rho, \quad \beta \in [0, 1]. \quad (11)$$

Если на одном шаге учитывается несколько взаимодействий, вектор $v_{j(i, t)}$ заменяется их взвешенным центроидом $\sum_{j \in S_i^t} \omega_t^{ij} v_j$, где $\omega_t^{ij} \propto \exp(f_t^{ij} / \tau_s)$ и $\sum_j \omega_t^{ij} = 1$. Однообъектная динамика (11) является частным случаем этого обновления.

Отклики добавляются в накопленную обучающую выборку $\mathcal{B}_{t+1} = \mathcal{B}_t \cup \{(i, j, Y_t^{ij}) : j \in S_i^t\}$. В момент переобучения параметры определяются минимизацией эмпирического риска

$$w^{t+1} = \arg \min_w \left\{ \frac{1}{|\mathcal{B}_{t+1}|} \sum_{(i, j, y) \in \mathcal{B}_{t+1}} \ell(y, f(u_i^{t+1}, v_j; w)) + \lambda R(w) \right\}, \quad (12)$$

где ℓ — функция потерь. В рассматриваемой задаче используется бинарная кросс-энтропия, определённая в (2). Функция $R(w)$ является регуляризатором, а $\lambda \geq 0$ — его коэффициент. Переобучение проводится периодически, а не после каждого шага взаимодействия. Если на шаге t переобучение не проводится, параметры рекомендательной модели не изменяются:

$$w^{t+1} = w^t.$$

После переобучения новая оценка пары имеет вид

$$f_{t+1}^{ij} = f(u_i^{t+1}, v_j; w^{t+1}).$$

Абстрактно обновление оценки можно записать как $f_{t+1}^{ij} = \mathcal{F}^{ij}(\mathcal{B}_{t+1}, u_i^{t+1}, v_j)$. В детерминированной динамике по условным средним, используемой для теоретического анализа, случайные Y_k^{mn} заменяются их ожиданиями η_k^{mn} . Тогда оператор обновления

зависит от истории $\{\eta_k^{mn}\}_{k \leq t}$. Существенно, что выборка содержит только пары, выбранные правилом (8); непоказанные объекты не дают обучающего сигнала [27, 2, 3].

Соберём состояния пользователей в вектор $x_t = (u_1^t, \dots, u_N^t) \in (\mathbb{R}^d)^N$ и введём расширенное состояние $z_t = (x_t, w^t, \mathcal{B}_t)$. Случайные активности и отклики обозначим через ξ_t . Приведённые скалярные уравнения задают функцию перехода

$$z_{t+1} = \Phi_t(z_t, \xi_t). \quad (13)$$

Именно скалярная запись (6)–(12) является основным определением динамики; оператор Φ_t служит её сокращённым обозначением в постановке задачи управления.

2.3 Используемые обозначения

Далее используются термины и обозначения дискретной теории управления. Пользовательская популяция рассматривается как управляемый объект, выдача — как управляющее воздействие, накопленная выборка — как измерение, а рекомендательная модель — как адаптивный регулятор. Этот язык выбирается не как внешняя аналогия: задача непосредственно формулируется как стохастическая задача оптимального управления для перехода (13). Подобные постановки используются при анализе влияния рекомендаций на вовлечённость, поляризацию и разнообразие [15, 16, 17, 18].

Таблица 1: Основные обозначения замкнутой системы управления

Обозначение	Смысл
$x_t = (u_i^t)_{i \in \mathcal{U}}$	состояние управляемого объекта, то есть популяции пользователей.
w^t	внутреннее состояние адаптивного регулятора, равное параметрам рекомендательной модели.
$z_t = (x_t, w^t, \mathcal{B}_t)$	расширенное состояние замкнутой системы.
$\mathcal{B}_t$	накопленная к шагу t обучающая выборка наблюдаемых откликов.
f_t^{ij}, S_i^t	скалярная оценка пары пользователь–объект и список рекомендаций.
$\mathcal{E}_i^t, \mathcal{I}_i^t$	множества просмотренных и доступных пользователю объектов.
θ, θ_t^{ij}	фиксированный закон истинного отклика и его текущее значение для пары (i, j) .
η_t^{ij}, Y_t^{ij}	наблюдаемая вероятность отклика и реализованный бинарный отклик.
Φ_t	функция перехода всей замкнутой системы.
β, ρ	параметры среды: сила изменения предпочтений и вероятность взаимодействия, изменяющего состояние пользователя.
$p, s, \alpha = ps$	параметры канала обратной связи: доля возвращаемого сигнала, степень следования рекомендации и совокупная сила обратной связи.
$D(t), Q(t)$	функционалы состояния и качества, используемые в задаче управления.

2.4 Формулировка задачи оптимального управления

Пусть аудитория разбита на K сегментов $\mathcal{U} = \mathcal{C}_1 \sqcup \dots \sqcup \mathcal{C}_K$ с весами $\pi_k = n_k/N$. Для кластера k обозначим через Σ_k^t выборочную ковариацию пользовательских состояний. Функционалом сохранения персонализации служит совокупное внутрикластерное разнообразие

$$D_k(t) = \text{tr} \Sigma_k^t, \quad D(t) = \sum_{k=1}^K \pi_k D_k(t), \quad (14)$$

убывание которого означает сближение пользовательских состояний внутри сегмента и потерю персонализации.

Одновременно различаются два показателя качества: наблюдаемое качество $Q^{\text{obs}}(t)$, вычисленное по логируемым откликам η_t^{ij} , и истинное качество $Q^{\text{true}}(t)$, вычисленное

по истинным вероятностям θ_t^{ij} . Их расхождение показывает, насколько оценка по собственным логам отличается от фактической полезности рекомендаций. Дополнительным функционалом состояния служит $\text{KL}(P_t \| P_0)$ — расхождение Кульбака–Лейблера между текущим и начальным распределениями пользовательских состояний. Такое разделение наблюдаемого и истинного качества соответствует постановке перформативного риска, в которой оцениваемое распределение зависит от самой модели [12, 13].

Пусть $\Pi = (\Pi_0, \dots, \Pi_{T-1})$ — допустимая стратегия управления на горизонте T , а $\mathfrak{P}$ — класс таких стратегий. На шаге t закон Π_t выбирает воздействие $\mathcal{A}_t$ по доступной истории состояний и наблюдений. Требование сохранить персонализацию без существенного снижения качества формулируется как задача ограниченного стохастического оптимального управления

$$\begin{aligned} \Pi^* &\in \arg \max_{\Pi \in \mathfrak{P}} \mathbb{E}_{\Pi} D(T), \\ \text{при условиях} \quad z_{t+1} &= \Phi_t(z_t, \xi_t), \quad t = 0, \dots, T-1, \\ \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}_{\Pi} Q^{\text{true}}(t) &\geq Q^{\text{base}} - \delta, \\ \mathcal{A}_t &\in \mathfrak{A}(z_t). \end{aligned} \tag{15}$$

Здесь Q^{base} — качество базовой рекомендательной стратегии, $\delta \geq 0$ — допустимая потеря качества, а $\mathfrak{A}(z_t)$ — множество допустимых списков рекомендаций. Целевая функция требует сохранить разброс пользовательских состояний к концу горизонта, ограничение не позволяет добиться этого ценой неприемлемого качества, а уравнение состояния учитывает как реакцию пользователей, так и адаптацию самой модели.

В настоящей работе задача (15) не решается в полном классе всех возможных стратегий. Сначала исследуются свойства перехода Φ_t и устанавливаются механизмы потери разнообразия, затем сравниваются несколько практически реализуемых законов формирования выдачи. Таким образом, теоретические результаты глав 3 и 4 описывают динамические ограничения задачи управления, а глава 6 проверяет частные допустимые стратегии.

2.5 Решаемые задачи

Целью работы является построение и анализ математической модели описанного контура, позволяющей отделить вклад переобучения в деградацию персонализации от прочих причин. Для достижения цели решаются следующие задачи.

1. Установить условия, при которых совокупное разнообразие $D(t)$ убывает, и получить оценку скорости убывания в терминах параметров модели.
2. Выяснить, является ли убывание разнообразия следствием переобучения или оно наступает и при замороженной модели, то есть универсально по режиму работы контура.

3. Определить, оставляет ли переобучение отделимый от универсального дрейфа след, и в какой геометрической характеристике распределения он измерим.
4. Предложить и проверить способы подавления нежелательного эффекта, сохраняющие качество выдачи.

Задачам 1–4 соответствуют главы 3–6: построение модели, теоремы о двух каналах деградации, вычислительная проверка и управление контуром.

3 Динамика замкнутой системы управления

В главе 2 рекомендательная система сформулирована покомпонентно для каждого пользователя i и объекта j . Основу модели составляют скалярные последовательности θ_t^{ij} , f_t^{ij} , η_t^{ij} и Y_t^{ij} вместе с векторной динамикой состояния u_t^i . В этой главе исследуются свойства полученного замкнутого контура, после чего вводятся геометрические характеристики, используемые в главе 4. Такая постановка объединяет модели петель обратной связи в рекомендательных системах и перформативное предсказание в среде с состоянием [3, 5, 14].

3.1 Один шаг скалярной динамики

На шаге t для каждой доступной пары (i, j) вычисляются два различных скаляра. Величина $\theta_t^{ij} = \theta(u_t^i, v_j)$ задаёт текущий истинный отклик, а f_t^{ij} — оценку рекомендательной модели. Закон θ один и тот же на всех шагах, но значение θ_t^{ij} меняется после обновления u_t^i . Поэтому изменение истинного отклика в модели не требует вводить зависящую от времени функцию $\theta_t(\cdot, \cdot)$.

Модель ранжирует только доступные объекты $\mathcal{S}_i^t = \mathcal{S} \setminus \mathcal{E}_i^t$ и формирует список S_i^t по (8). Для показанных пар вычисляется наблюдаемая вероятность η_t^{ij} по (9), после чего реализуются отклики Y_t^{ij} по (10). Выбранный объект меняет состояние пользователя согласно (11). Наконец, наблюдения добавляются в $\mathcal{B}_{t+1}$ и в моменты переобучения изменяют параметры модели по (12).

Таким образом, причинная цепочка для одной пары имеет вид

$$(u_t^i, v_j, w^t) \mapsto (\theta_t^{ij}, f_t^{ij}) \mapsto \eta_t^{ij} \mapsto Y_t^{ij} \mapsto (u_{t+1}^i, w^{t+1}).$$

Замыкание возникает потому, что обновлённые u_{t+1}^i и w^{t+1} входят в вычисление θ_{t+1}^{ij} и f_{t+1}^{ij} . Параметры (β, ρ) задают динамику пользовательской среды, а (p, s) — канал обратной связи [8, 26, 10].

3.2 Завышение наблюдаемых метрик

Прежде чем переходить к динамике вкусов, покажем, что уже сам факт обучения на загрязнённых логах разводит наблюдаемое и истинное качество. В этом подразделе предпочтения считаются статичными, и единственный источник эффекта — смесь (9).

Для пользователя i и двух доступных объектов j, j' на фиксированном шаге t обозначим $\Delta_{\theta,t} = \theta_t^{ij} - \theta_t^{ij'}$, $\Delta_{f,t} = f_t^{ij} - f_t^{ij'}$ и $\Delta_{\eta,t} = \eta_t^{ij} - \eta_t^{ij'}$ — истинную, предсказанную и наблюдаемую разности отклика.

Предложение 3.1 (Самоподкрепление). Наблюдаемая разность отклика разлагается в сумму

$$\Delta_{\eta,t} = (1 - \alpha)\Delta_{\theta,t} + \alpha\Delta_{f,t},$$

второе слагаемое которой всегда поддерживает порядок самой модели.

В частности, пусть выполнены условия:

- (1) модель поставила j выше j' , то есть $\Delta_{f,t} > 0$;
- (2) истинное ранжирование противоположно: $\theta_t^{ij} < \theta_t^{ij'}$ и $\Delta_{\theta,t} = -D < 0$.

Тогда логи подтвердят порядок модели, то есть $\Delta_{\eta,t} > 0$, при

$$\alpha > \frac{D}{D + \Delta_{f,t}}.$$

Доказательство. Разложение получается подстановкой (9) в определение $\Delta_{\eta,t}$. Неравенство $\Delta_{\eta,t} > 0$ равносильно $\alpha\Delta_{f,t} > (1 - \alpha)D$, откуда следует условие на α . $\square$

Обсуждение. Популяционные оптимумы метрик ранжирования (AUC, Precision@L, NDCG@L) упорядочивают объекты по убыванию наблюдаемого отклика η_t^{ij} , а не текущего истинного отклика θ_t^{ij} . Поэтому рост наблюдаемых метрик означает приближение к оптимуму относительно собственных логов модели, тогда как истинное качество в это же время может снижаться. Самоподкрепляющееся слагаемое $\alpha\Delta_{f,t}$ тем больше, чем сильнее оцениваемое ранжирование коррелирует с f_t^{ij} , то есть при оценке системы на её же выдаче. Следствие предложения 3.1 — невозможность диагностировать деградацию стандартным А/В-тестом на собственных данных; нужен критерий, опирающийся на геометрию распределения предпочтений, к построению которого мы и переходим. Этот вывод согласуется с результатами об алгоритмическом смещении в рекомендациях и ограничениях метрик, вычисляемых на смещённом распределении показов [6, 28, 27].

Предложение 3.1 объясняет завышение качественно; следующая оценка делает его количественным, ограничивая разрыв между наблюдаемым и истинным качеством расхождением между загрязнённым (9) и истинным (6) откликом.

Предложение 3.2 (Граница разрыва наблюдаемого и истинного качества). Пусть выполнены условия:

- (1) показатель качества есть среднее ограниченной функции отклика

$$Q(t) = \mathbb{E}_{(i,j) \sim \mu_t} \mathbb{E}_y g(y), \quad 0 \leq g \leq L;$$

- (2) для наблюдаемого качества $Q^{\text{obs}}(t)$ отклик распределён как $y \sim \text{Bern}(\eta_t^{ij})$;
- (3) для истинного качества $Q^{\text{true}}(t)$ отклик распределён как $y \sim \text{Bern}(\theta_t^{ij})$.

Тогда

$$\begin{aligned} |Q^{\text{obs}}(t) - Q^{\text{true}}(t)| &\leq L \mathbb{E}_{(i,j) \sim \mu_t} |\eta_t^{ij} - \theta_t^{ij}| \\ &\leq L \sqrt{\frac{1}{2} \overline{\text{KL}}_t}, \end{aligned}$$

где

$$\overline{\text{KL}}_t := \mathbb{E}_{(i,j) \sim \mu_t} \text{KL}(\text{Bern}(\eta_t^{ij}) \parallel \text{Bern}(\theta_t^{ij})).$$

Доказательство. Для ограниченной g и любой пары (i, j) имеем $|\mathbb{E}_{\text{Bern}(\eta_t^{ij})}g - \mathbb{E}_{\text{Bern}(\theta_t^{ij})}g| \leq LTV(\text{Bern}(\eta_t^{ij}), \text{Bern}(\theta_t^{ij})) = L|\eta_t^{ij} - \theta_t^{ij}|$, поскольку для бернуллиевских мер полная вариация равна разности параметров. Усреднение по μ_t даёт первое неравенство. По классическому неравенству Пинскера $|\eta_t^{ij} - \theta_t^{ij}| \leq \sqrt{\frac{1}{2} \text{KL}(\text{Bern}(\eta_t^{ij}) \parallel \text{Bern}(\theta_t^{ij}))}$; усреднение и вогнутость корня (неравенство Йенсена) дают второе. $\square$

Обсуждение. Неравенство связывает разрыв между качеством по логам и истинным качеством с расхождением между наблюдаемым и истинным откликом: наблюдаемая метрика остаётся надёжным прокси истинной ровно до тех пор, пока $\overline{\text{KL}}_t$ мало. Направление расхождения существенно: берётся $\text{KL}(\text{Bern}(\eta_t^{ij}) \parallel \text{Bern}(\theta_t^{ij}))$, конечное при $\theta_t^{ij} \in (0, 1)$, а не обратное, которое расходится при вырожденном отклике. Так как $\eta_t^{ij} - \theta_t^{ij} = \alpha(f_t^{ij} - \theta_t^{ij})$, переобучение на собственных логах может увеличивать расхождение между оценкой модели и текущим истинным откликом на показанных парах. Соответствующий рост $\overline{\text{KL}}_t$ и сопутствующее завышение измерены в разделе 5.9.

3.3 Дрейф вкусов как сжимающее отображение

Рассмотрим геометрию обновления (11). На одном шаге активный пользователь действительно смещается к эмбедингу конкретного выбранного объекта. Если двум пользователям одного кластера показан один и тот же объект v , то

$$u_i^{t+1} - u_k^{t+1} = (1 - \beta)(u_i^t - u_k^t),$$

то есть расстояние между ними умножается на $1 - \beta < 1$ за совместный отклик.

Однако в последовательные моменты времени выбираются, вообще говоря, разные объекты. Обозначим случайный эмбединг выбранного объекта через V_i^t и предположим, что для пользователей сегмента $\mathcal{C}_k$ распределение выдачи имеет условное среднее

$$\mathbb{E}[V_i^t \mid \mathcal{F}_t] = \bar{v}_k.$$

С учётом вероятности активности ρ из (11) условное среднее следующего состояния равно

$$\mathbb{E}[u_i^{t+1} \mid \mathcal{F}_t] = (1 - \rho\beta)u_i^t + \rho\beta\bar{v}_k, \quad (16)$$

поэтому

$$\mathbb{E}[u_i^{t+1} - \bar{v}_k \mid \mathcal{F}_t] = (1 - \rho\beta)(u_i^t - \bar{v}_k).$$

Таким образом, отдельная реализация траектории на каждом шаге направлена к конкретному объекту, но её систематическая составляющая направлена к среднему эмбедингу показанного контента. Отклонения отдельных объектов от этого среднего образуют шум, который определяет ненулевой остаточный разброс. Поэтому расстояние между двумя пользователями не обязано уменьшаться в каждой отдельной реализации; стягивание утверждается для условного среднего и второго момента.

Центр $\bar{v}_k$ возникает не как дополнительное правило динамики, а как математическое ожидание распределения объектов, показываемых сегменту. В частности, практический запрет повторных показов делает отдельный объект непостоянной точкой притяжения: на разных шагах пользователь получает разные объекты из одной области каталога. Если бы одному пользователю многократно показывался один фиксированный объект v^* , то уравнение (11) действительно приводило бы к сходимости именно к v^* . В исследуемой модели общим для последовательности показов остаётся не отдельный объект, а центр их распределения $\bar{v}_k$. Формальное соотношение между этим сжатием и остаточной дисперсией устанавливается в главе 4.

3.4 Кластеры, делимость и эхо-камера

Никакой конкретной вероятностной модели аудитории не предполагается. Кластер — элемент заданного разбиения; его описывают центроид $\bar{x}_k^t = \frac{1}{n_k} \sum_{i \in \mathcal{C}_k} u_i^t$, ковариация Σ_k^t и разнообразие $D_k(t) = \text{tr} \Sigma_k^t$. Разбиение называется делимым, если центры разнесены сильнее внутреннего разброса: $\Delta_{\min} > c \sigma_{\text{in}}$, где $\Delta_{\min} = \min_{k \neq l} \|\bar{x}_k^0 - \bar{x}_l^0\|$, $\sigma_{\text{in}}^2 = \max_k \text{tr} \Sigma_k^0$, $c > 0$. Подобные условия делимости используются в теории кластерной структуры и нужны здесь только для того, чтобы отличать внутрикластерное стягивание от слияния сегментов [29, 30].

Определение 3.3 (Эхо-камера). Кластер $\mathcal{C}_k$ находится в режиме эхо-камеры на шаге t , если существует область $\mathcal{V}_k^t \subset \mathbb{R}^d$ малого диаметра, такая что эмбединги объектов в выдаче почти каждого пользователя кластера лежат в $\mathcal{V}_k^t$. Иными словами, выдачи концентрируются в одной узкой области каталога, хотя конкретные идентификаторы объектов могут различаться.

Такое определение совместимо с фильтрацией просмотренных объектов: пользователь может последовательно получать разные объекты, но все они будут принадлежать одной малой области латентного пространства. Если фильтр повторных показов отключён, предельным случаем становится буквальное совпадение списков $\text{top-}L$. Малое разнообразие $D_k(t)$ само по себе ещё не гарантирует такого совпадения: при близких оценках близкие пользователи могут получать разные списки. Связь устанавливает следующая лемма; обозначим через Lip константу Липшица оценки f_w по аргументу u , а через $m > 0$ — зазор между L -й и $(L+1)$ -й оценками на общем множестве кандидатов.

Лемма 3.4 (Порог совпадения выдачи). Пусть пользователи i и i' имеют одно и то же множество доступных кандидатов, $\mathcal{S}_i^t = \mathcal{S}_{i'}^t$. Если

$$\|u_i^t - u_{i'}^t\| < \frac{m}{2\text{Lip}},$$

то пользователи i и i' получают одинаковый список $\text{top-}L$.

Доказательство. При сдвиге аргумента на δ каждая оценка меняется не более чем на $\text{Lip} \cdot \|\delta\|$. Относительный порядок L -го и $(L+1)$ -го объектов сохраняется, пока $2\text{Lip} \cdot \|\delta\| < m$; тогда $\text{top-}L$ не меняется. $\square$

При фильтрации просмотренного множества кандидатов у пользователей могут различаться, поэтому лемма не утверждает буквального совпадения их списков. Она показывает устойчивость ранжирования при одинаковом доступном каталоге; в общем случае убывание $D_k(t)$ приводит к концентрации различных доступных объектов в одной области $\mathcal{V}_k^t$, то есть к эхо-камере в смысле определения 3.3.

3.5 Гауссова модель выдачи и резкость

Чтобы описать влияние переобучения на форму выдачи, понадобится аналитически управляемая модель показанного контента. В кластере k примем, что пользовательские состояния распределены как $U_{k,t} \sim \mathcal{N}(m_{k,t}, S_{k,t})$, а объекты каталога — как $V_k^{\text{cat}} \sim \mathcal{N}(\mu_k, \Psi_k)$, $\Psi_k \succ 0$. Средние $m_{k,t}$ и μ_k не обязаны совпадать. Оценка модели вблизи своего максимума, расположенного в μ_k , аппроксимируется параболой

$$r_{A_{k,t}}(v) = -\frac{1}{2}(v - \mu_k)^\top A_{k,t}(v - \mu_k), \quad A_{k,t} \succeq 0, \quad (17)$$

а выдача — наклоном каталога $\pi_{k,t}(dv) \propto \exp(r_{A_{k,t}}(v)) \mathcal{N}(\mu_k, \Psi_k)(dv)$. Матрицу $A_{k,t}$ будем называть резкостью закона управления: она задаёт концентрацию управляющего воздействия в латентном пространстве объектов. Большие собственные значения отвечают узкому пику (показывается почти одно и то же), малые — пологому профилю (выдача разнообразна). Такая параметризация используется в моделях управления распределением показов, воздействующим на последующую динамику пользователей [15, 16].

Предложение 3.5 (Ковариация выдачи). Пусть $A_{k,t} \succeq 0$. Тогда показанный контент распределён как $\mathcal{N}(\mu_k, C_{k,t})$ с ковариацией

$$C_{k,t} = (\Psi_k^{-1} + A_{k,t})^{-1}.$$

Доказательство. Произведение двух гауссовых плотностей с точностями Ψ_k^{-1} и $A_{k,t}$ и общим центром μ_k есть гауссова плотность с точностью $\Psi_k^{-1} + A_{k,t}$ и тем же центром; обращение точности даёт $C_{k,t}$. $\square$

В этой модели μ_k является средним эмбеддингом показанного контента, то есть $\bar{v}_k = \mu_k$ в обозначениях (16). Если случайные векторы $U_{k,t}$ и $V_{k,t} \sim \mathcal{N}(\mu_k, C_{k,t})$ условно независимы, то после одного активного взаимодействия

$$U_{k,t+1} \mid a_t = 1 \sim \mathcal{N}((1 - \beta)m_{k,t} + \beta\mu_k, (1 - \beta)^2 S_{k,t} + \beta^2 C_{k,t}). \quad (18)$$

При вероятности активности ρ математическое ожидание всей популяции после одного шага удовлетворяет

$$m_{k,t+1} = m_{k,t} + \rho\beta(\mu_k - m_{k,t}), \quad m_{k,t+1} - \mu_k = (1 - \rho\beta)(m_{k,t} - \mu_k). \quad (19)$$

Следовательно, если средние пользователей и каталога различаются, уже за один шаг возникает ненулевой дрейф центра пользовательского распределения в сторону среднего показанного контента. В частном случае $m_{k,t} = \mu_k$ сдвиг среднего равен нулю, поэтому центрированная постановка скрывает этот компонент динамики и показывает только изменение ковариации.

Пример. В одномерном случае пусть $U_{k,t} \sim \mathcal{N}(0,1)$, каталог имеет среднее $\mu_k = 2$, $\beta = 0,1$, а $\rho = 0,8$. Тогда по (19)

$$m_{k,t+1} = 0 + 0,8 \cdot 0,1 \cdot (2 - 0) = 0,16.$$

За один шаг математическое ожидание пользовательского распределения смещается от 0 к 0,16, а расстояние до среднего каталога уменьшается с 2 до 1,84. При повторении динамики и неизменной выдаче это расстояние геометрически умножается на $1 - \rho\beta = 0,92$ на каждом шаге.

Формула $C = (\Psi^{-1} + A)^{-1}$ — центральная для анализа петлевого канала: разброс показанного тем меньше, чем больше резкость A , и в пределе $A \rightarrow \infty$ выдача стягивается в точку. Так как в центрированной модели центр притяжения дрейфа совпадает с центром каталога, $C_{k,t}$ есть в точности ковариация показанного, входящая в оценку разнообразия главы 4, то есть ковариация управляющего воздействия. Её уменьшение означает концентрацию воздействия на всё более узкой области каталога и потому напрямую связано с компромиссом между вовлечённостью и разнообразием [17, 18].

3.6 Условие включения петли

Переобучение способно перестроить выдачу лишь тогда, когда модель различает пользователей внутри кластера. Формальной мерой служит кластерный градиент оценки $J_k = \frac{1}{n_k} \sum_i \nabla_u f_w|_{u_i}$: при $\|J_k\| \approx 0$ оценка почти не зависит от пользователя, выдача одинакова для всех, и адаптация регулятора почти не получает информации о внутрикластерных различиях. Величина J_k является градиентом чувствительности закона управления по состоянию: если она мала, изменение пользовательского состояния почти не меняет выдачу. У билинейной модели $f = \sigma(\langle u, v \rangle)$ или у предобученного многослойного персептрона (MLP) оценка существенно зависит от u и $\|J_k\| \neq 0$. Различимость пользователей $\|J_k\| \neq 0$ есть необходимое условие работы петлевого канала; его роль проверяется экспериментально в разделе 5.7. Это локальное условие чувствительности, необходимое для наблюдаемости пользовательских различий через выдачу, но само по себе не является полным критерием наблюдаемости или управляемости системы [15, 18].

4 Два канала деградации: дрейф и переобучение

Деградация персонализации в построенной модели складывается из двух различных механизмов. Дрейфовый канал (раздел 4.1) отвечает за универсальное стягивание разнообразия и действует даже без переобучения. Петлевой канал (раздел 4.2) возникает только при переобучении: модель делает выдачу резче, ковариация показанного сужается, и стягивание углубляется. Первый механизм формализован Теоремой 4.3, второй — Теоремой 4.9. Такое разделение уточняет известные наблюдения об информационных пузырях, индуцированных сдвигами предпочтений и изменениях разнообразия под действием обратной связи: в данной модели общий коллапс и специфический след переобучения оказываются разными математическими каналами [7, 8, 26, 11].

4.1 Теорема о стягивании разнообразия

Будем работать при следующих предположениях.

- (A1) Сила дрейфа $\beta \in (0,1)$ постоянна; $\mathcal{F}_t$ — история процесса до шага t .
- (A2) Показанный пользователю объект представляется в виде $v_{j(i,t)} = \bar{v}_k + \xi_i^t$, где центр притяжения $\bar{v}_k$ фиксирован, а отклонение условно несмещено, $\mathbb{E}[\xi_i^t | \mathcal{F}_t] = 0$, с ограниченным вторым моментом

$$\mathbb{E}[\|\xi_i^t\|^2 | \mathcal{F}_t] \leq \sigma_\xi^2.$$

- (A3) Активность ρ независима от истории.
- (A4) Состав и идентичности пользователей кластера фиксированы на рассматриваемом горизонте; состояния u_i^t при этом обновляются согласно (11).

Предположение (A4) является модельным ограничением теоремы, а не утверждением о работающей рекомендательной системе. Оно позволяет сравнивать траектории одних и тех же пользователей и точно определять изменение внутрикластерной ковариации. В реальной системе аудитория обновляется; в вычислительном эксперименте этот эффект моделируется заменой части пользователей на каждом шаге. Поэтому теорема описывает динамику фиксированной когорты, а эксперимент дополнительно проверяет устойчивость результата к смене аудитории.

В предположении (A2) вектор $\bar{v}_k$ является условным математическим ожиданием показанного сегменту контента:

$$\bar{v}_k = \mathbb{E}[v_{j(i,t)} | \mathcal{F}_t, i \in \mathcal{C}_k].$$

Представление $v_{j(i,t)} = \bar{v}_k + \xi_i^t$ не заменяет каждый объект его центром: конкретное обновление по-прежнему направлено к отдельному $v_{j(i,t)}$. Разложение лишь отделяет общую для выдачи систематическую составляющую $\bar{v}_k$ от центрированного отклонения

ξ_i^t . Поэтому центр распределения показанного контента выступает аттрактором в среднем, а разброс отдельных показанных объектов входит в остаточный член оценки через σ_ξ^2 .

Наряду с разнообразием $D_k(t) = \text{tr} \Sigma_k^t$ удобна вторая мера разброса — средний квадрат отклонения от центра притяжения

$$M_k(t) = \frac{1}{n_k} \sum_{i \in \mathcal{C}_k} \|u_i^t - \bar{v}_k\|^2, \quad M_k(t) = D_k(t) + \|\bar{x}_k^t - \bar{v}_k\|^2 \geq D_k(t). \quad (20)$$

Анализ ведётся именно на M_k , поскольку для него рекуррентное соотношение замыкается точно, тогда как наивная рекурсия на D_k при асинхронной активности неверна. Связь $D_k \leq M_k$ из (20) затем переносит оценку на разнообразие.

Лемма 4.1 (Сжатие индивидуального отклонения). Пусть $\delta_i^t := u_i^t - \bar{v}_k$ и выполнены (A1)–(A3).

Тогда для каждого пользователя i

$$\mathbb{E}[\|\delta_i^{t+1}\|^2 \mid \mathcal{F}_t] \leq q \|\delta_i^t\|^2 + \rho \beta^2 \sigma_\xi^2, \quad q = 1 - \beta \rho (2 - \beta) < 1.$$

Доказательство. Для активного пользователя $\delta_i^{t+1} = (1 - \beta)\delta_i^t + \beta \xi_i^t$, для неактивного $\delta_i^{t+1} = \delta_i^t$. Возводя в квадрат нормы и беря условное матожидание, замечаем, что перекрёстное слагаемое $2\beta(1 - \beta)\langle \delta_i^t, \mathbb{E}[\xi_i^t \mid \mathcal{F}_t] \rangle$ обращается в нуль по (A2). Коэффициент при $\|\delta_i^t\|^2$ равен $\rho(1 - \beta)^2 + (1 - \rho) = 1 - \beta \rho (2 - \beta) = q$. $\square$

Лемма 4.2 (Рекурсия на M_k). Пусть выполнены (A1)–(A4). Тогда

$$\mathbb{E}[M_k(t+1) \mid \mathcal{F}_t] \leq q M_k(t) + \rho \beta^2 \sigma_\xi^2.$$

Доказательство. $M_k(t)$ есть среднее величин $\|\delta_i^t\|^2$ по пользователям; применяем лемму 4.1 к каждому слагаемому и усредняем. $\square$

Теорема 4.3 (Стягивание разнообразия). Пусть выполнены (A1)–(A4). Тогда для любого $t \geq 0$

$$\mathbb{E} D_k(t) \leq M_k(0) q^t + \frac{\beta \sigma_\xi^2}{2 - \beta}, \quad q = 1 - \beta \rho (2 - \beta) < 1.$$

Доказательство. Проведём доказательство по шагам.

1. Числовая рекурсия. Взяв безусловное матожидание в лемме 4.2, получаем $a_{t+1} \leq q a_t + c$ с $a_t = \mathbb{E} M_k(t)$ и $c = \rho \beta^2 \sigma_\xi^2$.
2. Решение. Разворачивая рекурсию, $a_t \leq q^t a_0 + c \sum_{j < t} q^j \leq q^t a_0 + c/(1 - q)$.
3. Остаточный уровень. Подставляя $1 - q = \beta \rho (2 - \beta)$, получаем $c/(1 - q) = \rho \beta^2 \sigma_\xi^2 / (\beta \rho (2 - \beta)) = \beta \sigma_\xi^2 / (2 - \beta)$.

4. Переход к разнообразию. По (20) $\mathbb{E}D_k(t) \leq \mathbb{E}M_k(t) = a_t$, что и завершает оценку. $\square$

Обсуждение Теоремы 4.3. Разнообразие убывает геометрически с множителем $q < 1$ к асимптотической нижней грани $\beta\sigma_\xi^2/(2-\beta)$. Эта грань пропорциональна разбросу показанного $\sigma_\xi^2 = \text{tr}\Sigma_\xi$: чем уже выдача, тем ниже грань и тем полнее стягивание. Множитель q зависит лишь от силы дрейфа β и активности ρ , но не от факта переобучения, — это ключевое для дальнейшего свойства универсальности. В отличие от работ, где деградация обычно связывается с повторным обучением на пользовательских откликах [6, 9], эта теорема показывает самостоятельную роль пользовательской динамики.

Следствие 4.4 (Отсутствие стягивания при $\beta = 0$). При $\beta = 0$ имеем $q = 1$, нижняя грань равна нулю, и $\mathbb{E}M_k(t) \leq M_k(0)$ — убывания нет.

Следствие 4.5 (Универсальность по режиму). Так как q и нижняя грань зависят только от β , ρ и концентрации выдачи σ_ξ , режимы с переобучением, без него и с переобучением на истинных вероятностях отклика подчиняются одному закону убывания.

Следствие 4.6 (Время до эхо-камеры). Уровень $\mathbb{E}M_k(t) \leq \varepsilon_0$ достигается за

$$T_{\text{collapse}} = O\left(\frac{\log(1/\varepsilon_0)}{\log(1/q)}\right)$$

шагов.

Следствия 4.4 и 4.5 дают важный методологический вывод: наблюдаемое в эксперименте стягивание $\text{tr}\Sigma$ — прямое следствие дрейфа предпочтений по концентрированной выдаче, а не переобучения как такового. Следствие 4.6 вместе с леммой 3.4 превращает «неизбежность эхо-камеры» в строгую оценку. Тем самым на вопрос о причине деградации (задача 2 раздела 2.5) дан полный ответ; остаётся выяснить, оставляет ли переобучение собственный, отделимый след.

4.2 Теорема о переформировании выдачи

Универсальность дрейфового канала означает, что искать след переобучения нужно не в объёме разброса, а в форме ковариации. Покажем, что переобучение сужает ковариацию показанного по сравнению с замороженной моделью.

Описанный в (17) наклон выдачи переобучается как улучшение политики с регуляризацией Кульбака–Лейблера: новая выдача максимизирует ожидаемый отклик, не отходя слишком далеко от прежней,

$$\pi_{k,t+1} = \arg \max_{\pi} \left\{ \mathbb{E}_{V \sim \pi} [\hat{c}_{k,t}(V)] - \frac{1}{\kappa} \text{KL}(\pi \| \pi_{k,t}) \right\}, \quad \kappa > 0. \quad (21)$$

Здесь $\hat{c}_{k,t}(v) = c^0 - \frac{1}{2}(v - \mu_k)^\top H_{k,t}(v - \mu_k)$ — локальное (тейлоровское) приближение среднего отклика кластера, а $H_{k,t} = -\nabla_v^2 \hat{c}_{k,t} \succeq 0$ — его кривизна, неотрицательная, когда отклик имеет в области выдачи локальный максимум (тематически связанный сегмент). В терминах управления $H_{k,t}$ является локальным гессианом функционала качества по объекту и задаёт кривизну критерия, по которому усиливается управляющее воздействие. Эта кривизна естественно возникает при обучении модели оценки релевантности на кликах по бинарной кросс-энтропии: при локально линейной по объекту оценке релевантности гессиан потерь равен $\mathbb{E}[\sigma(z)(1 - \sigma(z)) \nabla_v z \nabla_v z^\top] \succeq 0$. KL-регуляризованная форма (21) также близка к постановкам онлайн-оптимизации по обратной связи и оптимального управления, где управляющая политика должна улучшать целевой функционал, оставаясь близкой к безопасному или базовому режиму [31, 24, 17, 18].

Лемма 4.7 (Антимонотонность обращения). Пусть B_0 и B_1 — симметричные положительно определённые матрицы и

$$0 \prec B_0 \preceq B_1$$

в порядке Лёвнера. Тогда

$$B_1^{-1} \preceq B_0^{-1}.$$

Доказательство. Конгруэнция $M := B_0^{-1/2} B_1 B_0^{-1/2} \succeq I$ сохраняет порядок, у M собственные значения не меньше единицы, у M^{-1} — не больше единицы, то есть $M^{-1} \preceq I$; сопрягая обратно, получаем требуемое. $\square$

Предложение 4.8 (Рост резкости). Решение (21) есть экспоненциальное перевзвешивание

$$\pi_{k,t+1} \propto \pi_{k,t} e^{\kappa \hat{c}_{k,t}}.$$

При этом резкость выдачи растёт по закону

$$A_{k,t+1} = A_{k,t} + \kappa H_{k,t} \succeq A_{k,t}.$$

Доказательство. Экспоненциальный вид следует из вариационного принципа Гиббса для функционала (21). Произведение гауссовой выдачи с точностью $A_{k,t}$ на множитель $e^{\kappa \hat{c}_{k,t}}$ с точностью $\kappa H_{k,t}$ даёт гауссову выдачу с точностью $A_{k,t} + \kappa H_{k,t}$ и тем же центром. $\square$

Теорема 4.9 (Переформирование выдачи переобучением). Пусть выполнены условия:

- (1) в режиме петли модель переобучается по предложению 4.8 с $H_{k,t} \succeq 0$;
- (2) в режиме заморозки резкость постоянна: $A_{k,t}^{\text{stat}} \equiv A_{k,0}$;
- (3) начальные состояния двух режимов совпадают.

Тогда для ковариаций выдачи при всех t

$$A_{k,t}^{\text{closed}} = A_{k,0} + \kappa \sum_{s < t} H_{k,s} \succeq A_{k,0} \implies C_{k,t}^{\text{closed}} \preceq C_{k,t}^{\text{stat}}.$$

Доказательство. Накопленная добавка $A_{k,t}^{\text{closed}} - A_{k,0} = \kappa \sum_{s < t} H_{k,s} \succeq 0$ как сумма неотрицательно определённых матриц. Поэтому $\Psi_k^{-1} + A_{k,t}^{\text{closed}} \succeq \Psi_k^{-1} + A_{k,0} \succ 0$, и по лемме 4.7 обращение переворачивает порядок: $C_{k,t}^{\text{closed}} = (\Psi_k^{-1} + A_{k,t}^{\text{closed}})^{-1} \preceq (\Psi_k^{-1} + A_{k,0})^{-1} = C_{k,t}^{\text{stat}}$. $\square$

Обсуждение Теоремы 4.9. Поскольку след монотонен по порядку Лёвнера, $\text{tr} C_{k,t}^{\text{closed}} \leq \text{tr} C_{k,t}^{\text{stat}}$, то есть переобучение опускает разброс показанного σ_{ξ}^2 , а с ним — и асимптотическую нижнюю грань Теоремы 4.3. Стягивание вкусов углубляется ниже уровня, достижимого без переобучения. Более того, C сужается как матрица (по всем направлениям), поэтому сжатие анизотропно: оно проявляется не в смещении центра аудитории, а в переформировании ковариации. Это указывает, где искать след петли, и приводит к выбору метрики.

4.3 Метрика следа петли и условия активации

Чтобы отделить переформирование разброса от его объёма, удобна дисперсионная часть гауссова расхождения двух ковариаций,

$$\mathcal{D}(\Sigma_T \| \Sigma_0) = \frac{1}{2} (\text{tr}(\Sigma_0^{-1} \Sigma_T) - d + \ln \det \Sigma_0 - \ln \det \Sigma_T) \geq 0, \quad (22)$$

которая растёт и при уменьшении объёма, и при росте анизотропии. Полное расхождение $\text{KL}(P_T \| P_0)$ распадается на слагаемое сдвига центра $\frac{1}{2}(\mu_0 - \mu_T)^\top \Sigma_0^{-1}(\mu_0 - \mu_T)$ и дисперсионное слагаемое (22). Предсказание модели состоит в том, что специфический след петли сосредоточен именно в дисперсионном слагаемом. В терминах перформативного предсказания это означает, что риск связан не только со средним качеством модели, но и с изменением распределения данных, на котором она затем обучается [12, 13, 14].

Петлевой канал активируется не всегда. Из анализа персонализированной выдачи $\pi_A(v | u) \propto \mathcal{N}(\mu_k, \Psi_k)(v) \exp(-\frac{1}{2}(v - u)^\top A(v - u))$ следует, что её зависимость от пользователя описывается матрицей $B_A = C_A A$ с $\nabla_u m_A(u) = B_A \neq 0$ — то есть модель различает пользователей. В изотропном случае ($\Psi_k = \psi I$, $S_k = \sigma_u^2 I$, $A = aI$) полный разброс показанного убывает с резкостью тогда и только тогда, когда

$$\sigma_u^2 < \frac{1 + a\psi}{2a}. \quad (23)$$

Итог главы. Дрейфовый канал (Теорема 4.3) гарантирует стягивание разнообразия и универсален по режиму. Петлевой канал (Теорема 4.9) специфичен для переобучения: он сужает ковариацию выдачи, опуская нижнюю грань разнообразия и переформировывая ковариацию вкусов; он включается при различимости пользователей $\|J_k\| \neq 0$, наличии сегментной структуры $K \geq 2$ и выполнении порога (23). Тем самым

на третью задачу раздела 2.5 получен ответ: переобучение оставляет separable след, измеримый в дисперсионной части расхождения $\text{KL}(P_T \| P_0)$. Численная проверка обоих каналов составляет содержание главы 5. Пороговая природа этого условия соответствует интуиции теории управления: петля обратной связи становится существенной только тогда, когда управляющий сигнал действительно воздействует на состояние и возвращается в измерение [16, 15].

5 Вычислительный эксперимент

Цель экспериментов — проверить предсказания теорем 4.3 и 4.9 в управляемой среде, где каждый компонент контура поддается точному контролю, а затем убедиться в переносимости выводов на реальные данные. Синтетическая постановка позволяет изолировать исследуемый эффект от посторонних факторов — неоднородности поведения, шума измерений, случайностей обработки. Такой подход близок к симуляционным средам для рекомендательных систем и моделям с синтетической обратной связью, но здесь симулятор используется не для обучения политики, а для проверки механизма петли [23, 21, 20].

5.1 Постановка эксперимента

Симулятор воспроизводит один шаг контура из раздела 3.1: формирование списка $\text{top-}L$, отклик по модели следования, запись логов, дрейф (11), переобучение раз в T_{ret} шагов и подсчет метрик. Рекомендательная модель — многослойный персептрон (MLP), получающий конкатенацию представлений пользователя и объекта, со скрытым слоем ReLU, сигмоидным выходом и обучением методом Adam по бинарной кросс-энтропии; в части экспериментов используется матричная факторизация $f = \sigma(u^\top Mv + b)$. Нейросетевая оценка релевантности выбрана как стандартная современная альтернатива классическим матрично-факторизационным моделям [25]. Популяция порождается смесью K гауссиан; на каждом шаге доля наименее активных пользователей заменяется новыми, сгенерированными из текущего распределения. Тем самым симулятор снимает допущение о неизменном составе когорты, использованное в теоретическом анализе: идентичность части пользователей между соседними шагами не сохраняется.

В практической выдаче объект, уже показанный пользователю, обычно исключается из его последующих списков. В основной конфигурации симулятора используется фильтр `seen_filter`; доступный каталог пользователя исключает объекты, для которых зарегистрировано предыдущее взаимодействие. Это является приближением к продуктовому правилу фильтрации всех прошлых экспозиций, поскольку симулятор регистрирует в матрице не каждый показ, а наблюдаемый отклик. В отдельных диагностических запусках фильтр отключается, когда требуется изолировать геометрию закона выдачи от исчерпания доступного каталога; такие запуски оговариваются отдельно.

Для разделения механизмов сравниваются четыре режима, отличающиеся обработкой переобучения и силой контура (таблица 2). Базовая конфигурация: $d = 8$, $N = M = 300$, $K = 3$, $L = 10$, $T = 100$, $T_{\text{ret}} = 10$, замена 5% за шаг, $\alpha = 0,7$, $\beta = 0,005$, межкластерное расстояние 5,0; метрики усредняются по 5 независимым запускам. Исходный код доступен в репозитории¹.

¹Директория `code/` проекта.

Таблица 2: Режимы сравнения

Режим	Поведение
closed_loop	переобучение на собственных логах, $\alpha > 0$
static	$\alpha > 0$, модель заморожена
fresh_oracle	переобучение на истинных вероятностях отклика
no_influence	$\alpha = 0$, отклик только по истинной вероятности

5.2 Универсальность стягивания разнообразия

Согласно Теореме 4.3 и следствию 4.5, стягивание разнообразия определяется силой дрейфа β и не зависит от режима переобучения. Решающую проверку даёт варьирование β при прочих фиксированных параметрах. Тем самым проверяется более сильное утверждение, чем в работах о деградации из-за повторного переобучения: если $\beta > 0$, стягивание может возникать и без обновления модели [8, 11].




Рис. 1: Остаточное разнообразие $\text{tr} \hat{\Sigma}$ после T шагов как функция силы дрейфа β для четырёх режимов. При $\beta = 0$ стягивания нет ни в одном режиме; при $\beta > 0$ оно наступает одинаково во всех режимах с $\alpha > 0$, что подтверждает следствия 4.4 и 4.5.

При $\beta = 0$ след ковариации сохраняется на уровне $\text{tr} \hat{\Sigma} \approx 30$ во всех режимах, включая режим петли (рис. 1), что прямо подтверждает следствие 4.4. При $\beta = 0,005$ стягивание достигает максимума ($\text{tr} \hat{\Sigma} \approx 0,8$) во всех режимах с $\alpha > 0$. Дополнительный эксперимент со статической моделью при варьировании α показывает, что уже при $\alpha \geq 0,4$ стягивание достигает уровня петли, то есть переобучение не является его источником.




Рис. 2: Динамика следа ковариации $\text{tr} \hat{\Sigma}_t^y$ по четырём режимам. Стягивание наступает во всех режимах с дрейфом; режим без следования рекомендациям `no_influence` стягивается слабее за счёт большего разброса показанного.

Численные итоги приведены в таблице 3. Стягивание следа ковариации в режиме петли составляет $-96,9\%$, в режиме `no_influence` — $-86,1\%$; режимы `static` и `fresh_oracle` дают близкий к петле результат ($-96,8\%$ и $-97,4\%$), что согласуется со следствием 4.5: закон убывания общий для всех режимов с дрейфом.

Таблица 3: Итоговые метрики после $T = 100$ шагов (среднее по 5 запускам)

Режим	$\text{KL}(P_T \ P_0)$	$\text{tr} \hat{\Sigma}_T$	$\Delta \text{tr}, \%$
<code>closed_loop</code>	16,88	0,865	$-96,9$
<code>static</code>	17,25	0,878	$-96,8$
<code>fresh_oracle</code>	16,95	0,723	$-97,4$
<code>no_influence</code>	7,31	4,06	$-86,1$

5.3 K -модальная структура эхо-камер

Теорема 4.3 применяется к каждому кластеру отдельно, поэтому при $K > 1$ ожидается формирование K независимых зон стягивания при сохранении межкластерного зазора. Гипотеза проверяется на сетке значений числа кластеров $K \in \{1, 2, 4\}$ и межкластерного расстояния.




Рис. 3: Внутрикластерная дисперсия во времени при $K \in \{1, 2, 4\}$ и трёх значениях межкластерного расстояния. Дисперсия убывает на 77–85%, быстрее при большем K .

Внутрикластерная дисперсия убывает на 77% при $K = 1$, на 81% при $K = 2$ и на 85% при $K = 4$ (рис. 3); коэффициент силуэта при этом не деградирует ($0,634 \rightarrow 0,677$ при $K = 4$), то есть кластеры уплотняются, но не сливаются. Скорость стягивания растёт с K : чем теснее объекты к пользователям своего сегмента, тем эффективнее дрейф концентрирует эмбединги. Качественная картина показана на PCA-снимках (рис. 4): облака сжимаются к центроидам при сохранении расстояния между ними.




Рис. 4: Снимки эмбедингов (метод главных компонент) в моменты $t \in \{0, T/4, T/2, T-1\}$ при $K = 3$; цвет — кластер. Стягивание персонализации внутри кластеров при сохранении межкластерного разделения.

5.4 Геометрия стягивания

Ряд проверок уточняет геометрию предельного режима, предсказанного Теоремой 4.3. Спектральный радиус $\lambda_{\max}(\hat{\Sigma}_k)$ монотонно убывает для всех кластеров; для 23 независимых начальных распределений все траектории среднего следа монотонно убывают к нулю, что подтверждает глобальность аттрактора. Внутрикластерный индекс Жаккара рекомендаций растёт с 0,50 до 0,86 (+71%): к концу горизонта пользователи одного кластера получают почти одинаковые списки.




Рис. 5: Среднее попарное косинусное расстояние между пользователями. В режиме петли эмбединги становятся почти коллинеарны ($d_{\cos} \approx 0,11$), тогда как в `no_influence` сохраняется существенное угловое разнообразие ($d_{\cos} \approx 0,49$).

Среднее попарное косинусное расстояние (рис. 5) убывает в петле в 4,4 раза сильнее, чем в контрольном режиме, то есть кластер схлопывается к почти одномерному подпространству вдоль направления доминирующего объекта. Анализ фрагментации (рис. 6) показывает, что доля межкластерной дисперсии η^2 в петле растёт ($0,33 \rightarrow 0,46$): аудитория всё чётче распадается на изолированные сегменты.




Рис. 6: Доля межкластерной дисперсии η^2 во времени. В режиме петли рост выражен сильнее ($0,33 \rightarrow 0,46$), чем в `no_influence` ($0,36 \rightarrow 0,40$): популяция фрагментируется на изолированные сообщества.

5.5 Фазовая диаграмма стягивания

Теорема 4.3 предсказывает, что граница стягивания определяется произведением силы следования и активности. На сетке 8×8 по (α, ρ) (192 запуска) измерялась остаточная доля дисперсии.




Рис. 7: Фазовая диаграмма остаточной доли дисперсии в координатах (сила следования α , активность ρ). Граница стягивания определяется произведением $\alpha \cdot \rho$: чем оно больше, тем полнее стягивание.

При $\rho = 1$ остаточная доля монотонно убывает с 0,268 при $\alpha = 0$ до 0,018 при $\alpha = 1$ (рис. 7). Линии уровня диаграммы близки к гиперболам $\alpha\rho = \text{const}$, что согласуется с зависимостью множителя $q = 1 - \beta\rho(2 - \beta)$ и концентрации выдачи (через α) от этих двух параметров.

5.6 Наблюдаемое и истинное качество

Предложение 3.1 предсказывает, что наблюдаемое качество держится выше истинного на всём горизонте. Раздельное измерение качества (по логам и по истинным вероятностям отклика) подтверждает это (рис. 8): наблюдаемое качество снижается с 0,754 до 0,686 (−9%), истинное — с 0,690 до 0,662 (−4,1%), и наблюдаемое держится выше истинного во все моменты. Самоподкрепляющееся слагаемое $\alpha\Delta_f$ завышает наблюдаемую метрику ровно так, как предсказывает предложение 3.1. По смыслу это тот же источник риска, который в литературе обсуждается как смешение в логированных откликах и как причина для контрфактической или каузальной интерпретации логов [27, 2, 3].




Рис. 8: Наблюдаемое (по логам) и истинное (по вероятностям θ_t^{ij}) качество во времени. Наблюдаемое держится выше истинного на всём горизонте, что подтверждает предложение 3.1.

5.7 След петлевого канала в ковариации

Согласно Теореме 4.9, переобучение оставляет отдельный след в форме ковариации, а условием его появления служит различимость пользователей $\|J_k\| \neq 0$. Чтобы выделить этот след, измерялся разрыв между режимами петли и заморозки при разных классах модели и способах инициализации (факторный план $2 \times 3 \times 4 \times 30$ запусков). Такая диагностика близка к идее отделять собственные предпочтения от влияния рекомендателя, но здесь измеряется не восстановленный отклик, а геометрический след петли в ковариации [2, 5].




Рис. 9: Разрыв KL между режимами петли и заморозки по классу модели и инициализации. Сигнал петли значим для предобученного MLP, где оценка существенно зависит от пользователя ($\|J_k\| \neq 0$), и отсутствует при случайной инициализации.

При предобученной модели (тёплый старт), где $\|J_k\| \neq 0$, разрыв **KL** между петлёй и заморозкой значим и положителен, $+0,79$ (95%-й доверительный интервал $[0,64; 0,95]$), а разрыв по следу ковариации составляет $-0,16$ (рис. 9): петля даёт более глубокое и иначе устроенное сжатие. При случайной инициализации, когда оценка почти не зависит от пользователя, разрыв **KL** статистически незначим — в полном согласии с условием активации $\|J_k\| \neq 0$ из раздела 4.3.

Решающую проверку предсказания Теоремы 4.9 о локализации следа даёт разложение **KL** на слагаемое сдвига центра и дисперсионное слагаемое (таблица 4). Весь разрыв между петлёй и заморозкой сосредоточен в дисперсионном слагаемом ($+0,788$), тогда как сдвиг центра незначим ($+0,002$). Это прямо подтверждает, что петля действует на ковариацию предпочтений, а не на положение центров, как и предсказано обсуждением Теоремы 4.9.

Таблица 4: Разложение разрыва **KL** (петля минус заморозка) на слагаемые; среднее по 30 запускам, в скобках 95%-й доверительный интервал

Слагаемое	Разрыв (петля — заморозка)
KL полное	$+0,789 [0,66; 0,93]$
сдвиг центра	$+0,002 [-0,01; 0,01]$
дисперсионное слагаемое	$+0,788 [0,66; 0,93]$
$\text{tr} \hat{\Sigma}$	$-0,162 [-0,22; -0,11]$

Границы активации петлевого канала уточняет эксперимент с варьированием числа кластеров и баланса их весов (рис. 10). При $K = 1$ след петли отсутствует, при $K \geq 2$ значим (максимум $+0,79$ при $K = 3$, далее убывает с ростом K); при сильном перекосе весов сегментов сигнал также исчезает, так как доминирующий кластер делает популяцию практически одномодальной. Это согласуется с условием $K \geq 2$ из итога главы 4.




Рис. 10: Разрыв **KL** петля–заморозка в зависимости от числа сегментов K . Сигнал отсутствует при $K = 1$ и значим при $K \geq 2$, что подтверждает необходимость сегментной структуры для петлевого канала.

5.8 Прямая проверка оператора переобучения

Разложение расхождения локализует след петли в форме ковариации, но проверяет Теорему 4.9 косвенно — через геометрию вкусов, а не через сам оператор переобучения. Сама теорема опирается на предположение (21): переобучение действует как улучшение политики с регуляризацией Кульбака–Лейблера, заостряя резкость $A_{k,t}$ (предложение 4.8) и тем сужая ковариацию выдачи $C_{k,t}$. Проверим это предсказание напрямую, заменив в контуре переобучение на сам оператор (21) и измерив след ковариации показанного. Такая проверка связывает модель с онлайн-оптимизацией по обратной связи и оптимальным управлением замкнутой рекомендательной системой [17, 18].

В режиме петли кластерная политика инициализируется предобученной моделью (резкость $A_{k,0}$) и на каждом шаге переобучения перевзвешивается по Гиббсу, $S_k \leftarrow S_k + \kappa \hat{c}_k$, где $\hat{c}_k$ — средний по кластеру логируемый отклик (смесь истинного отклика и предсказания модели); в режиме заморозки политика неизменна. Прочие компоненты контура сохранены, старты режимов совпадают (парный план, 10 запусков, $T = 100$). Шаг переобучения κ варьировался для проверки дозовой зависимости.

Результаты (таблица 5) подтверждают предсказание. Кривизна отклика неотрицательна — предпосылка $H_{k,t} \succeq 0$ выполнена во всех кластерах, — а след ковариации выдачи в петле значимо меньше, чем при заморозке, причём разрыв растёт по модулю с шагом переобучения κ (от $-0,022$ при $\kappa = 5$ до $-0,083$ при $\kappa = 20$). Это прямо воспроизводит следствие $\text{tr} C_{k,t}^{\text{closed}} \leq \text{tr} C_{k,t}^{\text{stat}}$ из обсуждения Теоремы 4.9: под её собственным оператором переобучение заостряет выдачу, и тем сильнее, чем интенсивнее переобучение.

Таблица 5: Прямая проверка оператора переобучения (21): разрыв следа ковариации выдачи $\text{tr} C$ между режимами петли и заморозки; среднее по 10 запускам, в скобках 95%-й доверительный интервал

Величина	Значение
Кривизна отклика $H_{k,t} \succeq 0$ (доля кластеров)	100%
$\text{tr} C$, петля — заморозка ($\kappa = 5$)	$-0,022$ [$-0,027$; $-0,017$]
$\text{tr} C$, петля — заморозка ($\kappa = 20$)	$-0,083$ [$-0,103$; $-0,064$]

Проверка относится к идеализированному оператору (21). В промышленных системах переобучение минимизирует существенно более сложную функцию потерь — бинарную кросс-энтропию глубокой модели и её варианты, — оператор которой не сводится к чистому улучшению политики, и заострение выдачи в таком режиме достигается труднее. Поэтому приведённый результат подтверждает механизм Теоремы 4.9 в рамках её модельного допущения о форме переобучения, оставляя количественную силу эффекта в реальных архитектурах предметом дальнейшего изучения.

5.9 Рост расхождения и надёжность офлайн-метрик

Предложение 3.2 ограничивает разрыв между наблюдаемым и истинным качеством расхождением $\overline{KL}_t$ между загрязнённым и истинным откликом. Проверим, как $\overline{KL}_t$ ведёт себя в контуре и выполняется ли граница. На каждом шаге по показанным парам (распределение показов μ_t) измерялись $\overline{KL}_t$, завышение метрики $Q^{\text{obs}} - Q^{\text{true}}$ (наблюдаемый и истинный CTR показанного) и граница Пинскера; режимы петли, заморозки и без влияния, 8 запусков, $T = 100$. Такой эксперимент важен именно для офлайн-оценивания: стандартные метрики ранжирования зависят от того, какие пары пользователь–объект были показаны, и поэтому могут терять связь с истинной полезностью при смещённом распределении показов [28, 10].




Рис. 11: Расхождение $\overline{KL}_t$ между наблюдаемым и истинным откликом (слева), разрыв качества $|Q^{\text{obs}} - Q^{\text{true}}|$ (в центре) и его сравнение с границей Пинскера (справа, штрих) по трём режимам. В режиме петли расхождение и разрыв растут со шагом контура; в режиме без влияния ($\alpha = 0$) загрязнения нет.

Результаты (рис. 11, таблица 6) подтверждают предсказание. В режиме петли $\overline{KL}_t$ растёт со шагом контура (с почти нуля до 0,17), завышение метрики увеличивается синхронно — до +0,18 (наблюдаемый CTR 0,92 против истинной релевантности 0,74), — и величина разрыва тесно следует за $\sqrt{\overline{KL}_t}$ (коэффициент корреляции 0,93). Граница Пинскера выполняется на каждом шаге. Эффект специфичен для переобучения: при заморозке рост $\overline{KL}$ примерно впятеро слабее (разрыв петля–заморозка по $\overline{KL}$ значим, +0,14, доверительный интервал [0,13;0,15]), а в режиме без влияния загрязнения нет и $\overline{KL} \equiv 0$.

Таблица 6: Расхождение наблюдаемого и истинного отклика и разрыв качества на горизонте $t = T$; среднее по 8 запускам

Режим	$\overline{KL}_T$	$ Q^{\text{obs}} - Q^{\text{true}} _T$
closed_loop	0,165	0,182
static	0,024	0,047
no_influence	0,000	0,000

По мере работы контура наблюдаемое качество расходится с истинным не быстрее, чем позволяет $\overline{KL}_t$, и поскольку переобучение на собственных логах увеличивает это расхождение, офлайн-метрики перестают быть надёжным индикатором реальной пользы — в количественном согласии с Предложением 3.2.

5.10 Эксперименты на реальных данных

Для проверки переносимости выводов использован набор данных MovieLens-20M [32]. В первой постановке синтетический генератор пользователей заменён эмпирическим, восстановленным по матрице оценок (500×500 после фильтрации, $d = 16$, матричная факторизация, 3 запуска); прочие компоненты контура сохранены. Результаты воспроизводят синтетические: $\text{tr}\hat{\Sigma}$ в петле равен 0,174 против 0,339 в no_influence, а KL составляет 34,5 против 19,7 (разрыв 1,75 раза), причём с более выраженным разделением режимов (рис. 12). Использование MovieLens здесь не предполагает, что реальные логи являются нейтральной выборкой предпочтений: напротив, именно такие исторические данные мотивируют методы деконволюции и каузальной коррекции петли обратной связи [2, 6, 3].




Рис. 12: Динамика $KL(P_t \| P_0)$ и $\text{tr}\hat{\Sigma}_t$ на MovieLens-20M с эмпирическим генератором пользователей. Эффект воспроизводится вне синтетической среды.

Во второй постановке коллапс наблюдается непосредственно в распределении рекомендаций, без обращения к дрейфу эмбедингов: модель в режиме петли дообучается на собственных списках top- L (3000×3000 , $d = 32$, $L = 10$, 17 квартальных окон). Покрывание каталога падает с 0,68 до 0,24, а коэффициент Джини частот рекомендаций растёт с 0,67 до 0,91 (рис. 13); в контрольном режиме без переобучения изменения отсутствуют. Спустя моделируемый год система рекомендует втрое меньшую долю каталога, что подтверждает выводы на уровне работы системы.




Рис. 13: Прямое измерение стягивания распределения рекомендаций на MovieLens-20M: покрытие каталога, коэффициент Джини и разнообразие по трём режимам. В режиме петли покрытие падает более чем вдвое; контрольные режимы стабильны.

Третья постановка проверяет само допущение о дрейфе предпочтений (11): до сих пор сила дрейфа β задавалась как параметр модели и из данных не измерялась. В пространстве жанровых тегов **genome** (1128 признаков, выведенных из содержания фильмов и независимых от поведенческих эмбедингов; сжато методом главных компонент до 20 измерений) для каждого пользователя строилась временная траектория центроидов потребления по последовательным окнам просмотров. К ней применялась модель пространства состояний типа «случайное блуждание с шумом», в которой стационарность потребления отвечает $\beta = 0$, а отношение дисперсии дрейфа к дисперсии внутриоконного шума даёт оценку $\hat{\beta} = \sigma_v / \sigma_\epsilon$. На 9,9 млн положительных оценок (порог ≥ 4 , 47,9 тыс. пользователей) оценка дрейфа в 15–21 раз превосходит контрольное значение, полученное при перестановке порядка окон, по всем 20 компонентам, что свидетельствует о значимой нестационарности предпочтений во времени. Полученная верхняя граница по наблюдательным данным на силу дрейфа за один отклик составляет порядка 0,04–0,08, внутри которой используемое в симуляции значение $\beta = 0,005$ оказывается консервативным. Поскольку без экзогенной вариации показов рекомендательно-индуцированный дрейф неотделим от автономной эволюции вкусов, эта оценка является верхней границей; её каузальное уточнение намечено в главе 7.

5.11 Сводка: теория и эксперимент

Таблица 7 сопоставляет теоретические утверждения с их численным подтверждением. Все ключевые предсказания обеих теорем подтверждены, в том числе на реальных данных.

Таблица 7: Соответствие теоретических утверждений и эксперимента

Утверждение	Эксперимент	Результат
Предложение 3.1: наблюдаемое выше истинного	качество, рис. 8	$0,69 \rightarrow 0,66$ ниже $0,75 \rightarrow 0,69$
Теорема 4.3: нет стягивания при $\beta = 0$	варьирование β	$\text{tr } \hat{\Sigma} \approx 30$
Следствие 4.5: универсальность по режиму	режимы <code>static/oracle</code>	спад $\approx 97\%$
Теорема 4.3: монотонность по $\alpha\rho$	фазовая диа- грамма	$0,27 \rightarrow 0,02$
Теорема 4.3: глобальный аттрактор	23 инициализа- ции	все $\rightarrow 0$
Теорема 4.9: след петли при $\ J_k\ \neq 0$	тёплый старт MLP	$\text{tr } -0,16, \text{KL } +0,79$
Теорема 4.9: след в ковариации, не в центре	разложение KL	дисп. $+0,79$, центр $+0,00$
Условие $K \geq 2$	варьирование K	$K=1$: нет; $K \geq 2$: есть
Перенос на реальные данные	MovieLens-20M	$\text{tr } 0,17$ vs $0,34$

6 Управление контуром обратной связи

Теоремы главы 4 не только объясняют деградацию, но и указывают точки вмешательства. В этой главе из них выводится критерий риска и проверяется, какие стратегии формирования выдачи приближают решение задачи (15), сохраняя разнообразие без существенной потери качества. По смыслу это соответствует линии работ о смягчении эффектов петель обратной связи: вмешательство может быть каузальным, алгоритмическим или управленческим, но оно должно менять сам контур, а не только итоговую метрику [3, 10, 5].

6.1 Точки вмешательства

Асимптотическая нижняя грань разнообразия в Теореме 4.3 равна $\beta\sigma_\xi^2/(2-\beta)$ и пропорциональна разбросу показанного $\sigma_\xi^2 = \text{tr}\Sigma_\xi$. Отсюда прямое следствие: чтобы удержать разнообразие, нужно не позволять выдаче сужаться, то есть поддерживать σ_ξ^2 на ненулевом уровне. Петлевой канал (Теорема 4.9) действует в противоположную сторону — понижает σ_ξ^2 за счёт роста резкости A , поэтому управление сводится к двум независимым рычагам: ослаблению загрязнения логов $\alpha = ps$ (оно гасит и петлевой канал, и завышение наблюдаемых метрик из предложения 3.1) и прямому расширению выдачи. В терминах теории управления это два разных класса действий: изменение канала измерения и изменение управляющего сигнала выдачи [15, 18].

Петлевой эффект имеет мультипликативную природу: он возникает лишь при одновременном выполнении нескольких условий, и достаточно нарушить любое одно из них, чтобы его обезвредить. Перечень условий и соответствующих управляющих воздействий сведён в таблице 8. Такая таблица играет роль практического контрольного списка, аналогичного таксономическим подходам к классификации петель обратной связи и способов смягчения смещений [5, 10].

Таблица 8: Условия активации петлевого канала и рычаги управления

Условие	Символ	Рычаг управления
Модель различает пользователей	$\ J_k\ \neq 0$	холодный старт безопаснее; штраф на чувствительность оценки
Аудитория сегментирована	$K \geq 2$	контроль однородности сегментов
Логи загрязнены	$\alpha = ps > 0$	понижать p или s : исследовательские показы, взвешивание навязанных откликов
Выдача продолжает сужаться	$\sigma_\xi^2 \downarrow$	расширение выдачи, контроль резкости A

6.2 Сравнение стратегий выдачи

Чтобы выяснить, какое вмешательство действительно поддерживает разнообразие, сравнивались пять стратегий формирования списка: жадная $\text{top-}L$ (базовая), ϵ -жадная при $\epsilon \in \{0,1;0,3\}$, softmax с температурой $\tau = 2,0$ и стратегия с явным контролем разнообразия по алгоритму максимальной маргинальной релевантности (MMR). Оценивались сохранение следа ковариации $\text{tr} \hat{\Sigma}_T$ и качество выдачи после $T = 100$ шагов (таблица 9, рис. 14). Контроль разнообразия является классическим направлением в рекомендательных системах [1], но в данной работе он проверяется как управляющее воздействие на долгосрочную геометрию пользовательских состояний, а не только как одношаговый критерий качества.

Таблица 9: Сравнение стратегий выдачи после $T = 100$ шагов (среднее по 3 запускам)

Стратегия	$\text{tr} \hat{\Sigma}_T$	Качество
Базовая ($\text{top-}L$)	0,289	0,634
ϵ -жадная ($\epsilon=0,1$)	0,269	0,636
ϵ -жадная ($\epsilon=0,3$)	0,194	0,636
softmax ($\tau=2,0$)	0,084	0,642
Контроль разнообразия (MMR)	0,442	0,641




Рис. 14: Сохранение следа ковариации $\text{tr}\hat{\Sigma}_t$ для пяти стратегий выдачи. Явный контроль разнообразия (MMR) сохраняет дисперсию выше базовой стратегии; случайные стратегии (ϵ -жадная, softmax) усиливают стягивание.

Результат содержит контринтуитивный вывод. Случайные стратегии — ϵ -жадная и softmax — стягивание не ослабляют, а усиливают: случайные показы выводят пользователей на объекты из разных сегментов, в среднем расположенные ближе к центру пространства, и дрейф (11) стягивает всю популяцию к единой средней точке быстрее, чем жадная выдача. Напротив, стратегия с явным контролем разнообразия сохраняет след ковариации 0,442 против 0,289 у базовой — улучшение на 53% — при практически том же качестве (0,641 против 0,634). Механизм согласуется с разделом 6.1: MMR штрафует за сходство показанных объектов, поднимая σ_{ξ}^2 , а значит и нижнюю грань разнообразия Теоремы 4.3. Компромисс качество–разнообразие для всех стратегий показан на рис. 15.




Рис. 15: Компромисс между качеством выдачи и сохранением разнообразия для пяти стратегий. Стратегия с контролем разнообразия доминирует базовую, одновременно сохраняя качество.

Итог главы. Управление контуром эффективно тогда, когда оно нацелено на форму выдачи, а не на её случайность. Случайное исследование не защищает от стягивания и даже ускоряет его; защищает явное расширение выдачи в сочетании с понижением загрязнения логов $\alpha = ps$. Тем самым на четвёртую задачу раздела 2.5 получен конструктивный ответ: предложен критерий риска (таблица 8) и подтверждена работоспособность диверсификации выдачи как меры подавления петлевого канала. В отличие от чисто эвристического исследования выдачи, такой подход ближе к оптимальному управлению с ограничениями: качество выдачи должно оставаться не хуже приемлемого базового уровня, а управляющее воздействие должно ограничивать накопление долгосрочного риска [24, 17].

7 Заключение

Целью работы было построить математическую модель рекомендательного контура с переобучением на собственных логах и установить условия его деградации, отделив вклад переобучения от прочих причин. Вклад работы находится на стыке петель обратной связи в рекомендательных системах, перформативного предсказания и теории управления рекомендательными системами [3, 12, 15]. Поставленные задачи решены полностью.

Задача 1. Рекомендательная система формализована как замкнутая стохастическая система управления (главы 2 и 3): определены состояние, управляющее воздействие, измерение, функция перехода (13) и закон адаптации регулятора; выведено загрязнение логов (9) и показано (предложение 3.1), что обучение на загрязнённых логах превышает наблюдаемые метрики относительно истинных — рост наблюдаемого качества не равнозначен росту пользы. Этот вывод согласуется с работами о логированных откликах, алгоритмическом смещении и каузальной коррекции данных [2, 6, 27].

Задача 2. Доказана Теорема 4.3 о стягивании разнообразия: внутрикластерный разброс убывает геометрически с множителем $q = 1 - \beta\rho(2 - \beta)$ к асимптотической нижней грани $\beta\sigma_{\xi}^2/(2 - \beta)$. Получены следствия о времени достижения эхо-камеры и о зависимости границы стягивания от концентрации выдачи.

Задача 3. Установлено, что стягивание разнообразия универсально по режиму: оно определяется дрейфом предпочтений и наступает даже без переобучения (следствия 4.4 и 4.5). Отдельно доказана Теорема 4.9: переобучение сужает ковариацию выдачи по сравнению с замороженной моделью, опуская нижнюю грань разнообразия и переформируя ковариацию предпочтений. Тем самым переобучение оставляет отделимый след, измеримый в дисперсионной части расхождения $\text{KL}(P_T \| P_0)$; получены условия его активации — различимость пользователей, наличие сегментной структуры и порог концентрации.

Задача 4. Предсказания обеих теорем подтверждены серией вычислительных экспериментов (глава 5), в том числе на наборе MovieLens-20M: универсальность стягивания, отсутствие эффекта при $\beta = 0$, монотонность по $\alpha\rho$, локализация следа петли в дисперсии и условие $K \geq 2$. Предложен критерий риска и показано (глава 6), что явная диверсификация выдачи сохраняет разнообразие лучше базовой стратегии (+53% при том же качестве), тогда как случайное исследование стягивание усиливает.

Все полученные теоретические результаты строго доказаны и согласуются с вычислительными экспериментами; центральный тезис работы — петля переобучения оставляет специфический, отделимый от универсального дрейфа след в геометрии ковариации предпочтений — установлен теоретически и подтверждён численно. В терминах существующей литературы результат уточняет, какой именно компонент обучения в замкнутом контуре отвечает за наблюдаемую деградацию: динамика с состоянием даёт

универсальное стягивание, а повторное переобучение меняет форму выдачи [14, 13, 11].

Направления дальнейшей работы. В построенной модели закон отклика θ фиксирован, но его текущее значение θ_t^{ij} меняется вместе с состоянием пользователя u_i^t . Естественным развитием является учёт автономной динамики предпочтений, не сводящейся к воздействию потреблённых рекомендаций, а также перенос теоретических оценок с фиксированной когорты на систему с уходом и приходом пользователей. Перспективны прямое извлечение меры различимости пользователей $\|J_k\|$ и резкости выдачи из весов обученной модели как эксплуатационных метрик риска, отдельный анализ долей следования s и использования p , а также интервенции, нацеленные на форму ковариации выдачи. Отдельного внимания требует каузальная оценка силы дрейфа β : полученная в разделе 5.10 граница по наблюдательным данным не отделяет рекомендательно-индуцированный дрейф от автономной эволюции вкусов, и для такого разделения необходима экзогенная вариация показов — рандомизованные показы или регрессия на разрыве у границы отсечения списка. Практическая значимость результатов состоит в том, что полученные условия допускают мониторинг по наблюдаемым статистикам и могут служить основой раннего обнаружения деградации персонализации в промышленных рекомендательных сервисах. Это направление естественно продолжает каузальные методы для петель обратной связи и безопасные постановки управления с ограничением на качество базовой политики [3, 24, 18].

Список литературы

- [1] Adomavicius, Gediminas. Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions / Gediminas Adomavicius, Alexander Tuzhilin // IEEE Transactions on Knowledge and Data Engineering. — 2005. — Vol. 17, no. 6. — Pp. 734–749. <https://doi.org/10.1109/TKDE.2005.99>.
- [2] Sinha, Ayan. Deconvolving Feedback Loops in Recommender Systems / Ayan Sinha, David F. Gleich, Karthik Ramani // Advances in Neural Information Processing Systems. — Vol. 29. — Curran Associates, Inc., 2016. — Pp. 3243–3251. <https://proceedings.neurips.cc/paper/2016/hash/962e56a8a0b0420d87272a682bfd1e53-Abstract.html>.
- [3] Krauth, Karl. Breaking Feedback Loops in Recommender Systems with Causal Inference / Karl Krauth, Yixin Wang, Michael I. Jordan // arXiv. — 2022. — arXiv:2207.01616. <https://arxiv.org/abs/2207.01616>.
- [4] Khritankov, Anton. Hidden Feedback Loops in Machine Learning Systems: A Simulation Model and Preliminary Results / Anton Khritankov // Software Quality: Future Perspectives on Software Engineering Quality. — Cham: Springer International Publishing, 2021. — Vol. 404 of Lecture Notes in Business Information Processing. — Pp. 54–65. https://doi.org/10.1007/978-3-030-65854-0_5.
- [5] A Classification of Feedback Loops and Their Relation to Biases in Automated Decision-Making Systems / Nicolò Pagan, Joachim Baumann, Ezzat Elokda et al. // Equity and Access in Algorithms, Mechanisms, and Optimization. — ACM, 2023. — Pp. 1–14. <https://doi.org/10.1145/3617694.3623227>.
- [6] Chaney, Allison J. B. How Algorithmic Confounding in Recommendation Systems Increases Homogeneity and Decreases Utility / Allison J. B. Chaney, Brandon M. Stewart, Barbara E. Engelhardt // Proceedings of the 12th ACM Conference on Recommender Systems. — ACM, 2018. — Pp. 224–232. <https://doi.org/10.1145/3240323.3240370>.
- [7] Exploring the Filter Bubble: The Effect of Using Recommender Systems on Content Diversity / Tien T. Nguyen, Pik-Mai Hui, F. Maxwell Harper et al. // Proceedings of the 23rd International Conference on World Wide Web. — ACM, 2014. — Pp. 677–686. <https://doi.org/10.1145/2566486.2568012>.
- [8] Degenerate Feedback Loops in Recommender Systems / Ray Jiang, Silvia Chiappa, Tor Lattimore et al. // Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society. — ACM, 2019. — Pp. 383–390. <https://doi.org/10.1145/3306618.3314288>.

- [9] Feedback Loop and Bias Amplification in Recommender Systems / Masoud Mansoury, Himan Abdollahpouri, Mykola Pechenizkiy et al. // Proceedings of the 29th ACM International Conference on Information & Knowledge Management. — ACM, 2020. — Pp. 2145–2148. <https://doi.org/10.1145/3340531.3412152>.
- [10] Stoecker, Theodor. Bias Mitigation for AI-Feedback Loops in Recommender Systems: A Systematic Literature Review and Taxonomy / Theodor Stoecker, Samed Bayer, Ingo Weber // arXiv. — 2025. — arXiv:2509.00109. <https://arxiv.org/abs/2509.00109>.
- [11] The Diversity Paradox Revisited: Systemic Effects of Feedback Loops in Recommender Systems / Gianni Barlacchi, Alexander Felfernig, Markus Schedl, Marko Tkalčič // arXiv. — 2026. — arXiv:2602.16315. <https://arxiv.org/abs/2602.16315>.
- [12] Performative Prediction / Juan C. Perdomo, Tijana Zrnic, Celestine Mendler-Dünner, Moritz Hardt // Proceedings of the 37th International Conference on Machine Learning. — Vol. 119 of Proceedings of Machine Learning Research. — PMLR, 2020. — Pp. 7599–7609. <https://proceedings.mlr.press/v119/perdomo20a.html>.
- [13] Hardt, Moritz. Performative Prediction: Past and Future / Moritz Hardt, Celestine Mendler-Dünner // arXiv. — 2023. — arXiv:2310.16608. <https://arxiv.org/abs/2310.16608>.
- [14] Brown, Gavin. Performative Prediction in a Stateful World / Gavin Brown, Shlomi Hod, Iden Kalemaj // Proceedings of the 25th International Conference on Artificial Intelligence and Statistics. — Vol. 151 of Proceedings of Machine Learning Research. — PMLR, 2022. — Pp. 6045–6061. <https://proceedings.mlr.press/v151/brown22a.html>.
- [15] De Pasquale, Giulia. Recommender Systems as Control Systems / Giulia De Pasquale, Sarah Dean, Paolo Frasca // arXiv. — 2026. — arXiv:2605.01503. <https://arxiv.org/abs/2605.01503>.
- [16] Control Strategies for Recommendation Systems in Social Networks / Ben Sprenger, Giulia De Pasquale, Raffaele Soloperto et al. // arXiv. — 2024. — arXiv:2403.06152. <https://arxiv.org/abs/2403.06152>.
- [17] Mariano, Simone. Optimal Control Synthesis of Closed-Loop Recommendation Systems over Social Networks / Simone Mariano, Paolo Frasca // arXiv. — 2026. — arXiv:2603.10275. <https://arxiv.org/abs/2603.10275>.
- [18] Network-Aware Recommender System via Online Feedback Optimization / Sanjay Chandrasekaran, Giulia De Pasquale, Giuseppe Belgioioso, Florian Dörfler //

- IEEE Transactions on Automatic Control. — 2026. — Vol. 71, no. 3. — Pp. 1708–1723. <https://doi.org/10.1109/TAC.2025.3616262>.
- [19] Schmit, Sven. Human Interaction with Recommendation Systems / Sven Schmit, Carlos Riquelme // Proceedings of the 21st International Conference on Artificial Intelligence and Statistics. — Vol. 84 of Proceedings of Machine Learning Research. — PMLR, 2018. — Pp. 862–870. <https://proceedings.mlr.press/v84/schmit18a.html>.
- [20] Afsar, M. Mehdi. Reinforcement Learning Based Recommender Systems: A Survey / M. Mehdi Afsar, Trafford Crump, Behrouz Far // ACM Computing Surveys. — 2022. — Vol. 55, no. 7. — Pp. 1–38. <https://doi.org/10.1145/3543846>.
- [21] Wang, Wenlin. Learning to Recommend from Sparse Data via Generative User Feedback / Wenlin Wang // Proceedings of the AAAI Conference on Artificial Intelligence. — 2021. — Vol. 35, no. 5. — Pp. 4436–4444. <https://doi.org/10.1609/aaai.v35i5.16570>.
- [22] Veprikov, Andrey. A Mathematical Model of the Hidden Feedback Loop Effect in Machine Learning Systems / Andrey Veprikov, Alexander Afanasiev, Anton Khritankov // arXiv. — 2024. — arXiv:2405.02726. <https://arxiv.org/abs/2405.02726>.
- [23] RecSim: A Configurable Simulation Platform for Recommender Systems / Eugene Ie, Chih-Wei Hsu, Martin Mladenov et al. // arXiv. — 2019. — arXiv:1909.04847. <https://arxiv.org/abs/1909.04847>.
- [24] Chow, Yinlam. Constrained Stochastic Optimal Control with a Baseline Performance Guarantee / Yinlam Chow, Mohammad Ghavamzadeh // NIPS Workshop on Learning, Inference and Control of Multi-Agent Systems. — Montréal: 2014. <https://arxiv.org/abs/1506.06210>.
- [25] Neural Collaborative Filtering / Xiangnan He, Lizi Liao, Hanwang Zhang et al. // Proceedings of the 26th International Conference on World Wide Web. — International World Wide Web Conferences Steering Committee, 2017. — Pp. 173–182. <https://doi.org/10.1145/3038912.3052569>.
- [26] Estimating and Penalizing Induced Preference Shifts in Recommender Systems / Micah D. Carroll, Anca Dragan, Stuart Russell, Dylan Hadfield-Menell // Proceedings of the 39th International Conference on Machine Learning. — Vol. 162 of Proceedings of Machine Learning Research. — PMLR, 2022. — Pp. 2686–2708. <https://proceedings.mlr.press/v162/carroll122a.html>.

- [27] Counterfactual Reasoning and Learning Systems: The Example of Computational Advertising / Léon Bottou, Jonas Peters, Joaquin Quiñonero-Candela et al. // Journal of Machine Learning Research. — 2013. — Vol. 14, no. 101. — Pp. 3207–3260. <https://www.jmlr.org/papers/v14/bottou13a.html>.
- [28] Krichene, Walid. On Sampled Metrics for Item Recommendation / Walid Krichene, Steffen Rendle // Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. — ACM, 2020. — Pp. 1748–1757. <https://doi.org/10.1145/3394486.3403226>.
- [29] Hartigan, John A. Consistency of Single Linkage for High-Density Clusters / John A. Hartigan // Journal of the American Statistical Association. — 1981. — Vol. 76, no. 374. — Pp. 388–394. <https://doi.org/10.1080/01621459.1981.10477658>.
- [30] Chaudhuri, Kamalika. Rates of Convergence for the Cluster Tree / Kamalika Chaudhuri, Sanjoy Dasgupta // Advances in Neural Information Processing Systems. — Vol. 23. — Curran Associates, Inc., 2010. — Pp. 343–351. <https://proceedings.neurips.cc/paper/2010/hash/b534ba68236ba543ae44b22bd110a1d6-Abstract.html>.
- [31] Boyd, Stephen. Convex Optimization / Stephen Boyd, Lieven Vandenberghe. — Cambridge: Cambridge University Press, 2004. — P. 716. <https://doi.org/10.1017/CB09780511804441>.
- [32] Harper, F. Maxwell. The MovieLens Datasets: History and Context / F. Maxwell Harper, Joseph A. Konstan // ACM Transactions on Interactive Intelligent Systems. — 2015. — Vol. 5, no. 4. — Pp. 1–19. <https://doi.org/10.1145/2827872>.