

Анализ петель обратной связи в рекомендательных
системах в линейном приближении
68-я Научная конференция МФТИ

С.А. Дементьев А.С. Хританков

Московский физико-технический институт
Долгопрудный, Россия

2025

Коллаборативная фильтрация при следовании рекомендациям неизбежно порождает эхо-камеры

Проблема. Рекомендательные системы работают итеративно: алгоритм $\rightarrow$ выдача $\rightarrow$ смещённые данные $\rightarrow$ дообучение. Замыкание петли положительной обратной связи сужает информационное разнообразие [3, 2].



Постановка. Как математически описать эволюцию **гетерогенной** аудитории в такой петле и найти условия коллапса?

Решение. Предложена локальная линеаризация нелинейного оператора в окрестности макрокластеров и доказана теорема о K -компонентном вырождении распределения.

Главное сообщение: предложена математическая модель петли обратной связи для гетерогенной аудитории методом линеаризации, обеспечивающая строгое доказательство неизбежности K -компонентной эхо-камеры.

За 5 итераций переобучения нормальное распределение аудитории коллапсирует в бимодальное

Распределение попарного косинусного расстояния $d(u_i, u_j)$ между эмбедингами пользователей. Датасет MovieLens 100K, $K = 2$.



Алгоритм геометрически «склеивает» пользователей внутри макрокластеров. Это прямое следствие доказанной теоремы о K -компонентной эхо-камере.

До этого не было построено математической модели эффекта, подтвержденной экспериментом

Источник	Основной результат	Ограничение
Khritankov, 2023 [3]	Положит. обратная связь $\rightarrow$ concept drift	Качественный анализ
Veprikov et al., 2025 [5]	Достаточные условия сходимости $f_t \rightarrow \delta(x)$,	Однородная аудитория, рассмотренно узкое семейство операторов перехода
Zhou et al., 2025 [6]	Усиление смещения источника в петле	Эмпирически
Jiang et al., 2019 [2]	Формирование эхо-камер в RecSys	Феноменологически

Состояние системы задаётся K -компонентной смесью в латентных пространствах

Состояние системы в момент t — пара плотностей в латентных пространствах:

$$(\rho_U^t, \rho_I^t) \in \mathcal{P}(\mathcal{U}) \times \mathcal{P}(\mathcal{I}), \quad \dim \mathcal{U} > \dim \mathcal{I}$$

Гетерогенная аудитория моделируется K -компонентной GMM:

$$\rho_U^0 = \sum_{k=1}^K w_k \mathcal{N}(\mu_k, \Sigma_k), \quad \sum_{k=1}^K w_k = 1$$

Σ_k — внутрикластерная ковариация (микроперсонализация внутри k -го сегмента аудитории).

Задача: исследовать как нелинейный оператор переобучения $\rho^{t+1} = D(\rho^t)$ меняет матрицу Σ_k с течением времени t .

Линеаризация политики сводит нелинейную динамику к применению сжимающего оператора

Локальное приближение. Заменяем сложную нейросеть локальным якобианом $W_{k,t}$ в окрестности центра кластера μ_k .

Эволюция якобиана. Переобучение с L_2 -регуляризацией λ индуцирует обновление:

$$W_{k,t+1} = W_{k,t} \cdot M_{k,t}, \quad M_{k,t} = \Sigma_k (\Sigma_k + \lambda I)^{-1}$$

Условие сжатия:

$$\rho(M_{k,t}) < 1$$

Спектральный радиус оператора обновления строго меньше единицы при любом $\lambda > 0$.

Это позволяет строго проанализировать долгосрочную динамику $W_{k,t}$ и $\Sigma_k(t)$.

Теорема: при $\rho(M_k) < 1$ внутрикластерная дисперсия исчезает, формируя эхо-камеры

Теорема (Формирование K -компонентной эхо-камеры)

Если спектральный радиус $\rho(M_{k,t}) < 1$, то:

- ❶ **Норма якобиана** убывает экспоненциально: $\|W_{k,t}\| \xrightarrow{t \rightarrow \infty} 0$.
- ❷ **Внутрикластерная дисперсия** выдачи исчезает.
- ❸ Распределение объектов **сходится к дельта-мерам**:



$$\rho_I^t \xrightarrow{t \rightarrow \infty} \sum_{k=1}^K w_k \delta(x - c_k)$$

Следствие. При $\lambda > 0$ условие сжатия выполнено *всегда*, в рамках сделанных предположений. Коллаборативная фильтрация **неизбежно** уничтожает внутрикластерную микроперсонализацию.

MovieLens: нормальное распределение ($t = 0$) деформируется в бимодальное ($t = 5$)

Протокол. MovieLens 100K [1]; коллаборативная фильтрация (BPR) [4]; 5 итераций цикла «рекомендация $\rightarrow$ взаимодействие $\rightarrow$ обучение». Метрика: $d_{\cos}(u_i, u_j) = 1 - \frac{\langle u_i, u_j \rangle}{\|u_i\| \|u_j\|}$.

Плотность косинусных расстояний внутри аудитории (слева — $t = 0$, справа — $t = 5$).



Переобучение на собственных логах стягивает пользователей в геометрически неразличимые точки ($d \approx 0$).
Эмпирическая динамика точно соответствует пределу $\sum_k w_k \delta(x - c_k)$ при $K = 2$.

Предложен строгий спектральный критерий неизбежности эхо-камер в гетерогенной среде

Предложена математическая модель петли обратной связи для гетерогенной аудитории методом линеаризации, обеспечивающая строгое доказательство неизбежности K -компонентной эхо-камеры.

Также получены результаты:

- 1 Достаточное условие сходимости к эхо-камере: L_2 -регуляризация неизбежно ведёт к коллапсу $\Sigma_{\text{within}} \rightarrow 0$. (т.е. внутригрупповая дисперсия падает)
- 2 Измеримый критерий $\rho(M_k)$ для оценки скорости деградации системы.

References

- [1] F. Maxwell Harper and Joseph A. Konstan. The MovieLens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems*, 5(4):19:1–19:19, 2015.
- [2] Ray Jiang, Silvia Chiappa, Tor Lattimore, András György, and Pushmeet Kohli. Degenerate feedback loops in recommender systems. In *Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society*, pages 383–390. ACM, 2019.
- [3] Anton Khritankov. Positive feedback loops lead to concept drift in machine learning systems. *Applied Intelligence*, 53:22648–22666, 2023.
- [4] J. Ben Schafer, Dan Frankowski, Jon Herlocker, and Shilad Sen. Collaborative filtering recommender systems. In *The Adaptive Web*, pages 291–324. Springer, 2007.
- [5] Andrey Veprikov, Alexander Afanasyev, and Anton Khritankov. A mathematical model of the hidden feedback loop effect in machine learning systems. *Knowledge and Information Systems*, 67(12):11425–11454, 2025.
- [6] Yucheng Zhou et al. Exploring the escalation of source bias in user, data, and recommender system feedback loop. In *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 1676–1686. ACM, 2025.