

Алгоритм распознавания скрытых петель обратной связи
в рекомендательных системах
Выпускная квалификационная работа бакалавра

Дементьев Сергей Андреевич

Кафедра интеллектуального анализа данных, ФПМИ МФТИ
ВЦ им. А. А. Дородницына РАН

Научный руководитель: к.ф.-м.н. Хританков А. С.

Москва, 2026

Постановка задачи

Объект: рекомендательная система, переобучаемая на данных, порожденных собой же.

Проблема. Система переобучается на собственных логах, а пользователь кликает по *показанному*. Наблюдаемые метрики (CTR, NDCG) растут, но как оценки они смещены. Под воздействием рекомендательной системы аудитория изменяется.


Цель: построить модель эффекта как динамическую систему; установить условия деградации, **отделив вклад переобучения**.

Задачи:

- 1 формализовать петлю как динамическую систему;
- 2 оценить скорость стягивания разнообразия;
- 3 найти, где измерим след переобучения;
- 4 проверить предсказания численно.

Данные рекомендательной системы — пары пользователь—объект

наблюдаемые взаимодействия



Объекты постановки.

- пользователи u_i , объекты каталога v_j ;
- датасет:


$$\mathcal{B} = \{(u_i, v_j, y_{ij}) : (i, j) \in \Omega\};$$

- y_{ij} — зафиксированный отклик: покупка, клик, положительная оценка.
- $u, v \in \mathbb{R}^n$. Вложение построено так, что $\langle u, v \rangle$ является мерой релевантности объекта v для пользователя u .

В рек. системах используют регрессию, обучение метрике и ранжирование; в этой работе — **предсказание клика**.

$$Y_{ij} \sim \text{Bern}(\eta(u_i, v_j)), \quad \eta(u_i, v_j) = \mathbb{P}(Y_{ij} = 1 \mid u_i, v_j).$$

Динамическая система для средних



$$\theta_t^{ij} := \theta(u_i^t, v_j) = \sigma\left(\frac{\langle u_i^t, v_j \rangle}{\tau}\right), \quad (1) \quad \eta_t^{ij} = (1-\alpha)\theta_t^{ij} + \alpha f_t^{ij}, \quad \alpha = \rho s \in [0, 1] \quad (4)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$Y_t^{ij} \sim \text{Bern}(\eta_t^{ij}), \quad j \in S_i^t \quad (5)$$

$$f_t^{ij} := f(u_i^t, v_j; w^t) \in [0, 1] \quad (2)$$

$$S_i^t = \text{TopL}_{j \in \mathcal{I}_i^t} f_t^{ij}, \quad |S_i^t| = L \quad (3) \quad u_i^{t+1} = (1-\rho)u_i^t + \rho((1-\beta)u_i^t + \beta v_{j_i^t}),$$

$$\mathbb{P}(a_i^t = 1) = \rho, \quad \beta \in [0, 1]. \quad (6)$$

Система в замкнутом виде: $z_t = (x_t, w^t, \mathcal{B}_t)$, $z_{t+1} = \Phi_t(z_t, \xi_t)$.

Выдача выбирается как управляющее воздействие.

Оптимальное управление максимизирует качество при стабилизации аудитории

Дискретная управляемая система

$$a_t = \Pi_t(z_t) \in \mathcal{A}(z_t), \quad z_{t+1} = \Phi_t(z_t, a_t, \xi_t) Q(t) = \mathbb{E}_{(i,j) \sim \mu_t} \mathbb{E}_y g(y), \quad 0 \leq g \leq L.$$

a_t — выбранная выдача; Π_t — политика управления.

Функционал качества рекомендаций

μ_t — распределение показанных пар; g — ограниченная функция отклика.

Стабилизируемая величина

$$D_k^t = \text{tr } \Sigma_k^t, \quad D^t = \sum_{k=1}^K \pi_k D_k^t.$$

Σ_k^t — ковариация пользователей сегмента k ;

D_k^t не оптимизируется, а удерживается в допустимой зоне.

$$Q^{\text{obs}}(t) : \quad y \sim \text{Bern}(\eta_t^{ij}),$$

$$Q^{\text{true}}(t) : \quad y \sim \text{Bern}(\theta_t^{ij}).$$

Задача стабилизации дискретного управления

$$\Pi^* \in \arg \max_{\Pi \in \mathfrak{P}} \mathbb{E}_{\Pi} \left[\frac{1}{T} \sum_{t=0}^{T-1} Q^{\text{true}}(t) \right]$$

$$\text{при } a_t = \Pi_t(z_t), \quad z_{t+1} = \Phi_t(z_t, a_t, \xi_t),$$

$$\underline{D}_k \leq \mathbb{E}_{\Pi} D_k^t \leq \overline{D}_k,$$

$$k = 1, \dots, K, \quad t = 1, \dots, T.$$

Для каждого сегмента задаётся допустимый коридор разнообразия.

Расхождение между наблюдаемым и истинным качеством

Предложение 3.1: самоподкрепление

$$\Delta_{\eta,t} = (1 - \alpha)\Delta_{\theta,t} + \alpha\Delta_{f,t}.$$

$\Delta_{\theta,t}$, $\Delta_{f,t}$, $\Delta_{\eta,t}$ — истинная, модельная и наблюдаемая разности отклика для двух объектов.

Если модель поставила j выше j' , но истинный порядок противоположен:

$$\Delta_{f,t} > 0, \quad \Delta_{\theta,t} = -D < 0,$$

то логи всё равно подтвердят модель при

$$\alpha > \frac{D}{D + \Delta_{f,t}}.$$

Предложение 3.2: канал разрыва качества

$$\begin{aligned} |Q^{\text{obs}}(t) - Q^{\text{true}}(t)| &\leq L \mathbb{E}_{\mu_t} \left| \eta_t^{ij} - \theta_t^{ij} \right| \\ &\leq L \sqrt{\frac{1}{2} \overline{\text{KL}}_t}. \end{aligned}$$

$$\overline{\text{KL}}_t = \mathbb{E}_{\mu_t} \text{KL} \left(\text{Bern}(\eta_t^{ij}) \parallel \text{Bern}(\theta_t^{ij}) \right).$$

Второе неравенство — следствие неравенства Пинскера и вогнутости корня.

Теоретические оценки вырождения аудитории

Теорема 1 (Дементьев, 2026)

Пусть:

$$D_k^t = \text{tr } \Sigma_k^t, \quad M_k^t := \frac{1}{n_k} \sum_{i \in \mathcal{C}_k} \|u_i^t - \bar{v}_k\|^2, \quad D_k^t \leq M_k^t.$$

И при условиях (A1) - (A4):

$$\mathbb{E} D_k^t \leq M_k^0 q^t + \frac{\beta \sigma_\xi^2}{2 - \beta}, \quad q = 1 - \beta \rho(2 - \beta) < 1.$$

Частный случай модели гауссовой смеси

Фиксируем кластер вкусов k . $v \in \mathbb{R}^d$ — вектор объекта; μ_k — центр тематики; Ψ_k — естественный разброс каталога.

$$V_k^{\text{cat}} \sim \mathcal{N}(\mu_k, \Psi_k).$$

Рекомендатель заостряет каталог.


$$r_k^t(v) = -\frac{1}{2} (v - \mu_k)^\top A_k^t (v - \mu_k), \quad A_k^t \succeq 0.$$

A_k^t — **резкость** выдачи: чем больше A , тем сильнее штраф за удаление от центра.

$$\pi_k^t(dv) \propto \exp\{r_k^t(v)\} \mathcal{N}(\mu_k, \Psi_k)(dv).$$

$$V_k^t \sim \mathcal{N}(\mu_k, C_k^t),$$

$$C_k^t = (\Psi_k^{-1} + A_k^t)^{-1}$$



Модельное упрощение. Политика π_k^t общая для кластера: внутри сегмента модель не различает отдельных пользователей. Поэтому теорема говорит о кластерном механизме, а не о полной персонализации MLP.

Описание эксперимента

Шаг симуляции: $\text{top-}L \rightarrow \text{клики} \rightarrow \text{логи} \rightarrow \beta\text{-дрейф} \rightarrow \text{переобучение} \rightarrow \text{метрики}$.

Четыре режима — чтобы разделить эффекты взаимодействия

- `closed_loop` — полная петля;
- `static` — модель заморожена, $\alpha > 0$ (без переобучения);
- `fresh_oracle` — честное переобучение;
- `no_influence` — $\alpha = 0$.


`closed_loop` — `static` = вклад переобучения.

Данные: синтетические данные (GMM) и MovieLens-20M.


β -дрейф и петлевой KL-сигнал разделяются

Влияние β : при $\beta = 0$ коллапса нет; при $\beta > 0$ объём стягивается во всех режимах с $\alpha > 0$.

Эксперимент B: эффект β во всех режимах (5 seeds $\times$ 5 β)




Анализ KL-дивергенции: оставлены предобученные warm и warm_noisy; петлевой вклад виден как разрыв closed_loop–static.



Воспроизводимость на MovieLens-20M

Слева — коллапс разнообразия $\text{tr} \hat{\Sigma}_u^t$; справа — дрейф распределения вкусов $\text{KL}(P^t \| P^0)$.



Реальные данные MovieLens-20M (N=500, d=16, T=80, $\alpha=0.7$, $\beta=0.005$)



Вывод. Система с петлёй обратной связи будет иметь $\text{tr} \hat{\Sigma}_k^t$ и KL отличающимися от режима без петли. Эти функционалы позволяют хорошо диагностировать петлю на реальных данных

Коллапс популяции — это следствие дрейфа (6), а не петли (4)

Слева — разнообразие $\text{tr} \hat{\Sigma}^t$ по четырём режимам; справа — фазовая диаграмма по загрязнению α и активности ρ .



Вывод. Петля, заморозка и честное переобучение коллапсируют одинаково $\Rightarrow$ коллапс — это дрейф. **Теорема 1 подтверждена.**

Выносятся на защиту

- 1 **Математическая модель** рекомендательной системы со скрытой петлей (динамическая система (1)-(6); предложения 3.1 и 3.2).
- 2 **Теорема 1 (Дементьев, 2026)** о стягивании разнообразия; А также Теорема 2 (Дементьев, 2026) о перестроении выдачи.
- 3 **Создана имитационная модель**. Для неё был сделан экспериментальный стенд, который позволил проверить качественно свойства исследуемой системы
- 4 **Получены парето-оптимальные политики** для экспериментального датасета MovieLens-20M, которые показывают качество лучше.

Одобрение научным сообществом Данное исследование выиграло 68-ую конференцию МФТИ. Работа подана на конференцию ICOMP.

Ограничения и дальнейшая работа

Ограничения

- знак вклада петли в *истинное* качество не установлен;
- оценки некоторых эффектов имеют только качественный характер;
- эксперименты проверяли практическую модель, а не теоретическую

Дальнейшая работа

- резкость A и $\|J_k\|$ из весов как метрика риска;
- отдельный анализ usage p и adherence s ;
- решение задачи оптимального управления;
- открытый приток пользователей.

Список литературы

- [1] Ray Jiang, Silvia Chiappa, Tor Lattimore, András György, and Pushmeet Kohli. Degenerate feedback loops in recommender systems. In *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society (AIES)*, pages 383–390, 2019.
- [2] Anton Khritankov. Hidden feedback loops in machine learning systems. *Applied Intelligence*, 53(22):28047–28063, 2023.
- [3] J Ben Schafer, Dan Frankowski, Jon Herlocker, and Shilad Sen. Collaborative filtering recommender systems. In *The Adaptive Web*, pages 291–324. Springer, 2007.
- [4] Andrey Veprikov, Andrey Afanasyev, and Anton Khritankov. On the existence and properties of hidden feedback loops in recommender systems. *Knowledge and Information Systems (KAIS)*, 2025.
- [5] Yang Zhou et al. Amplification of source bias in feedback loops of recommender systems. In *Proceedings of ACM SIGIR*, 2025.